

УНИВЕРЗИТЕТ У БЕОГРАДУ
МАТЕМАТИЧКИ ФАКУЛТЕТ



Душан Пантелић

АНАЛИЗА УТИЦАЈА ХИЈЕРАРХИЈСКОГ
УСКЛАЂИВАЊА НА ТАЧНОСТ
ПРЕДВИЂАЊА ВРЕМЕНСКИХ СЕРИЈА
МОДЕЛИМА МАШИНСКОГ УЧЕЊА

мастер рад

Београд, 2016.

Ментор:

др Младен НИКОЛИЋ, ванредни професор
Универзитет у Београду, Математички факултет

Чланови комисије:

др Бојана МИЛОШЕВИЋ, ванредни професор
Универзитет у Београду, Математички факултет

др Мирјана МАЉКОВИЋ РУЖИЧИЋ, доцент
Универзитет у Београду, Математички факултет

Датум одбране: _____

Наслов мастер рада: Анализа утицаја хијерархијског усклађивања на тачност предвиђања временских серија моделима машинског учења

Резиме: Управљање ланцима снабдевања захтева прецизно предвиђање потражње на више нивоа агрегације, што је значајно отежано изразитом интермитентношћу података. Циљ овог рада био је да се испита утицај различитих метода хијерархијског усклађивања на прецизност базних прогноза и квантификује губитак математичке кохерентности приликом хеуристичког третмана негативних вредности. Истраживање је спроведено на скупу од 20.000 временских серија, уз евалуацију једанаест алгоритама (од статистичких модела до савремених фундаменталних мрежа). Базне прогнозе су подвргнуте структурном и темпоралном усклађивању (*OLS*, *WLS_Struct*, *WLS_Var*, *MinT_Shrink*), уз упоредну анализу строге оптимизације (QP) и хеуристичког одсецања на нулу. Резултати показују да усклађивање не побољшава универзално тачност система. Фундациони модели (*Chronos*, *TimesFM*) остварују најбоље перформансе, док детерминистичко усклађивање (*OLS*) драстично деградира њихов прецизан локални сигнал. Показано је да темпорално усклађивање функционише примарно као пост-хок регуларизатор који значајно ублажава грешке изразито лоших модела (пад грешке до 60% код *LightGBM*-а), али истовремено квари сигнале прецизних алгоритама. Такође, доказано је да хеуристичко одсецање негативних прогноза доводи до просечног нарушавања кохерентности од 6.00%, што се применом *WLS_Var* методе своди на занемарљивих 0.5%. Закључак указује да хеуристичко одсецање, упарено са методама које поштују историјску варијансу, представља супериорнију праксу у односу на нестабилне QP решаваче, пружајући директне смернице за пројектовање робусних предиктивних система у разматраном домену.

Кључне речи: хијерархијске временске серије, хијерархијско усклађивање, предвиђање временских серија, интермитентна потражња, машинско учење, дубоко учење, фундаментални модели, статистички модели

Садржај

1	Увод	1
1.1	Контекст и значај проблема/области	1
1.2	Дефиниција истраживачког проблема	3
1.3	Примарни циљеви рада	4
1.4	Кључни резултати	5
1.5	Преглед структуре рада	6
2	Теоријске основе	8
2.1	Основни концепти предвиђања временских серија	8
2.2	Хијерархијске и груписане временске серије	9
2.3	Методе за усклађивање предвиђања	12
3	Дизајн истраживања и методологија	22
3.1	Методолошки оквир истраживања	22
3.2	Карактеристике и припрема скупа података	22
3.3	Поставка и процес спровођења експеримента	27
4	Резултати и дискусија	36
4.1	Анализа перформанси основних (неусклађених) предвиђања	36
4.2	Упоредна анализа метода за усклађивање	38
4.3	Валидација и нарушавање хијерархијске кохерентности	43
4.4	Дискусија добијених резултата	46
4.5	Идентификација најбољих пракси за дати проблем	47
5	Закључак	49
5.1	Синтеза кључних налаза истраживања	49
5.2	Ограничења спроведене студије	50
5.3	Препоруке за будућа истраживања и практичну примену	51

Глава 1

Увод

Предвиђање (прогнозирање) временских серија (енгл. time series forecasting) представља фундаменталну област машинског учења и примењене статистике, која за циљ има екстракцију образаца из секвенцијалних података. Иако ови концепти налазе примену у разним доменима, од обраде сигнала до метеорологије, њихов највећи практични утицај је у домену пословних система и ланаца снабдевања [14]. Данашње свакодневно пословно окружење карактерише изузетна динамичност, која је резултат непредвидивости и све веће сложености тржишта. Способност организација да доносе правовремене одлуке на основу предвиђања будућих догађаја директно утиче на њихову стабилност и конкурентност. Међутим, реални подаци који описују пословне системе ретко су изоловане временске серије. Наиме, подаци унутар једне организације готово увек поседују инхерентну хијерархијску или групну структуру. Усклађивање ових процеса кроз све нивое одлучивања представља један од највећих изазова [10].

1.1 Контекст и значај проблема/области

Предвиђање у системима са хијерархијама захтева предвиђање догађаја на различитим нивоима агрегације. Хијерархије се могу поделити на две основне димензије:

1. **Структуралне:** Представљају просторну или логичку агрегацију/декомпозицију података у фиксном временском интервалу. На пример, у глобалном ланцу снабдевања, укупна светска тражња се декомпонује на регионе,

државе, дистрибутивне центре, и на крају на појединачне артикле (енгл. Stock Keeping Unit – SKU).

2. **Временске:** Подразумевају агрегацију података високе учесталости (нпр. дневне трансакције) у ниже фреквенције (недељне, месечне, годишње серије), што омогућава моделовање краткорочних оперативних осцилација и дугорочних стратешких трендова [3].

Традиционално се овом проблему приступа применом хеуристичких метода. Приступ „од дна ка врху” (енгл. Bottom-Up) предвиђа само најниже нивое који се потом сабирају [6], али је изузетно осетљив на висок ниво шума карактеристичан за податке на ниском нивоу. Са друге стране, приступ „од врха ка дну” (енгл. Top-Down) користи стабилност агрегираних података на вишим нивоима [8], али често не успева да прецизно декомпонује информације, губећи битне локалне карактеристике података [2]. Независно генерисане прогнозе на различитим нивоима су по правилу математички некохерентне (збир нижих нивоа не одговара прогнози вишег нивоа), што може довести до контрадикторних пословних одлука.

Као примарно решење овог проблема развијена је парадигма оптималног усклађивања (енгл. Optimal Reconciliation) [9], са методом минималног трага (енгл. Minimum Trace – MinT) као тренутним стандардом [21]. Иако је иницијални мотив за развој ових метода била административна кохерентност, новија сазнања указују на то да усклађивање заправо функционише као механизам регуларизације [12]. Приморавањем модела са различитих нивоа да „комуницирају”, усклађивање омогућава пренос информација, стабилност и ниска варијанса са виших нивоа хијерархије спуштају се на нижи ниво, док се карактеристични сигнали са дна пењу ка врху. Управо ова информациона размена, а не пука математичка кохерентност, представља потенцијал за унапређење предиктивних система.

Досадашња литература је овај домен претежно анализирала кроз употребу класичних модела машинског учења и статистичких модела. Скорашњи напредак архитектура дубоког учења [13, 17], као и појава тзв. фундаменталних (енгл. Foundation) модела обучених на масивним скуповима података [1, 7], захтевају потпуно нову евалуацију у контексту хијерархијског усклађивања.

1.2 Дефиниција истраживачког проблема

Суштина истраживачког проблема лежи у промени парадигме: усклађивање независних прогноза се у овом раду не посматра искључиво као захтев за изједначавање збирова, већ као механизам за побољшање предиктивности кроз размену информација између нивоа хијерархије. Проблем се огледа у проналажењу оптималног математичког модела који ће ово омогућити. Метод минималног трага постиже размену информација ослањајући се на апроксимацију коваријационе матрице грешака ван узорка, помоћу података из узорка (резидуала или историјских вредности). Међутим, примена ове методологије на реалне податке открива неколико изазова којима се овај рад првенствено бави:

- 1. Проблем апроксимације структуре грешака:** Иако увођење пуне узорачке коваријационе матрице (основна варијанта методе минималног трага) теоријски омогућава најпотпунији пренос информација, њена примена на хијерархије са великим бројем временских серија је статистички и нумерички нестабилна. Када број временских серија (20.000) драстично превазилази број расположивих историјских опсервација (60), пуна узорачка матрица коваријансе постаје дефицитарног ранга и сингуларна, што онемогућава њену инверзију [19]. Услед ових ограничења, варијанте са пуном узорачком коваријансом су искључене из анализе. Истраживање се фокусира на евалуацију преосталих стабилних алтернатива: OLS (метод обичних најмањих квадрата) и WLS_Struct (метод пондерисаних најмањих квадрата заснован на структури хијерархије) које нестабилност заобилазе ослањајући се на геометрију и топологију хијерархије без анализе грешака, WLS_Var (метод пондерисаних најмањих квадрата заснован на варијанси) која уводи само дијагоналне варијансе резидуала, као и напредне регуларизационе технике MinT_Shrink, која поступком математичког „скупљања” (енгл. shrinkage) стабилизује пуну матрицу коваријансе.
- 2. Сукоб математичке кохерентности и физичких ограничења:** Усклађивање често резултује негативним прогнозама, што је у контексту прогнозирања потражње физички немогуће и доводи до деградације евалуационих метрика. Формална ограничења ненегативности се успешно имплементирају кроз квадратно програмирање/оптимизацију, што за

последицу има прелазак са аналитичког решења на итеративно тражење оптимума. Овај прелазак уводи озбиљне нумеричке изазове и рачунарску комплексност у условима високе димензионалности и ограниченог историјског узорка. Иако ова појава зависи од специфичне топологије података и резидуала, она у оквиру нашег експеримента изазива да итеративни поступци за емпиријске методе (*WLS_Var* и *MinT_Shrink*) доживљавају нумерички слом услед лоше кондиционираности матрица израчунатих из резидуала. Насупрот њима, детерминистичке методе (*OLS* и *WLS_Struct*) успешно конвергирају на нашим подацима. С обзиром на то да овај рад евалуира перформансе модела и са формалним ограничењима и кроз стратегију хеуристичког одсецања вредности на нулу (енгл. *clipping to zero*), отвара се истраживачко питање: Како избор између строге математичке кохерентности и накнадних интервенција утиче на прецизност прогноза на циљаном (базном) нивоу и да ли се задржавају бенефити преноса информација.

3. **Хетерогеност структура грешака:** Различите класе модела генеришу суштински различите обрасце резидуала. Истраживачки изазов је разумевање интеракције ове хетерогености унутар метода за усклађивање и како утичу на коначан резултат.

1.3 Примарни циљеви рада

Да би се успешно одговорило на дефинисани истраживачки проблем, постављени су следећи примарни циљеви:

1. **Системска евалуација примењивих *MinT* варијанти:** Спровести свеобухватну компаративну анализу четири методе усклађивања (*OLS*, *WLS_Struct*, *WLS_Var* и *MinT_Shrink*) на структуралним и временским хијерархијама.
2. **Анализа утицаја ограничења ненегативности:** Испитати како увођење формалних ограничења ненегативности (за *OLS* и *WLS_Struct*), у поређењу са стратегијом накнадног хеуристичког одсецања вредности на нулу утиче на метрике. Циљ је демонстрирати да се предности размене информација кроз нивое могу задржати чак и када је строга

математичка кохерентност делимично нарушена ради очувања пословне логике и рачунарских перформанси.

3. Компаративна евалуација четири фамилије предиктивних модела:

- Статистички модели (*ARIMA*, *Holt-Winters*, *Prophet*).
- Класични модели машинског учења (*LightGBM*, *RandomForest*).
- Модели дубоког учења (*DeepAR*, *N-HITS*).
- Фундациони модели за временске серије (*Chronos*, *TimesFM*).

4. Идентификација најбољих пракси: Синтетизовати резултате у јасне смернице које ће допринети лакшем избору оптималне комбинације модела, методе усклађивања и стратегије третмана негативних прогноза у реалним пословним системима.

1.4 Кључни резултати

Свеобухватна експериментална евалуација спроведена у овом раду довела је до неколико значајних налаза који преиспитују традиционалне претпоставке о хијерархијском усклађивању:

- **Супериорност савремених архитектура:** На посматраном скупу података, претходно обучени фундациони модели и пробабилистичке неуронске мреже вишеструко надмашују класичне алгоритме машинског учења. Стабла одлучивања са стандардном функцијом циља показују масивну пристрасност и нису адекватна за серије са великим бројем нула.
- **Ограничења хијерархијског усклађивања:** Показано је да усклађивање не побољшава аутоматски прецизност базних прогноза. Детерминистички приступи најчешће деградирају прецизне локалне сигнале, док је квалитет добрих модела могуће сачувати искључиво применом метода које интелигентно скалирају корекције.
- **Темпорално усклађивање као регуларизатор:** Усклађивање кроз време не доноси стварну предиктивну вредност већ оптималним алго-

ритмима. Оно делује примарно као механизам пост-хок регуларизације који ублажава екстремне грешке модела лошијих перформанси.

- **Оправданост инжењерског компромиса:** Показано је да строга математичка оптимизација за спречавање негативних прогноза није рачунарски одржива у високодимензионалним корпоративним системима. Једноставно хеуристичко одсецање негативних вредности (енгл. *Clipping*) представља супериорни правац, јер обезбеђује физички смислене прогнозе уз занемарљив губитак агрегационе кохерентности.
- **Утицај дизајна хијерархије:** Комплекснија структура хијерархије уноси додатни шум у систем. Редуковање броја агрегационих нивоа значајно ублажава деградацију базних прогноза услед смањеног броја алгебарских ограничења.

1.5 Преглед структуре рада

Рад је конципиран тако да читаоца систематски води кроз релевантне теоријске концепте до свеобухватне анализе резултата, и подељен је у пет поглавља:

- Поглавље 1 (Увод): Дефинише широк контекст и значај истраживања, формализује истраживачки проблем усклађивања временских серија, поставља циљеве и наводи кључне доприносе.
- Поглавље 2 (Теоријске основе): Излаже статистичку теорију прогнозирања, дефинише својства хијерархијских структура и пружа математички преглед метода за усклађивање.
- Поглавље 3 (Дизајн истраживања и методологија): Описује експериментални оквир, карактеристике скупова података из реалног пословног окружења, архитектуре предиктивних модела, поставку експеримента и дефинише метрике евалуације.
- Поглавље 4 (Резултати и дискусија): Садржи компаративну анализу перформанси неусклађених и усклађених прогноза и идентификацију најбољих пракси.

- Поглавље 5 (Закључак): Синтетизује кључне налазе, даје критички осврт на ограничења спроведене студије и дефинише смернице за будућа академска истраживања.

Глава 2

Теоријске основе

Ово поглавље поставља формални математички и статистички оквир неопходан за разумевање проблема предвиђања у сложеним системима. Први део поглавља уводи основне концепте временских серија. Затим се дефинишу алгебарске структуре хијерархијских и груписаних временских серија. Коначно, трећи део поглавља доноси детаљан теоријски преглед метода за усклађивање предвиђања.

2.1 Основни концепти предвиђања временских серија

Временска серија се математички дефинише као низ опсервација посматраних у узастопним, најчешће једнако удаљеним временским интервалима. Нека је y_t вредност посматране променљиве у тренутку t . Временска серија дужине T може се представити као секвенца $\mathbf{y} = (y_1, y_2, \dots, y_T)$. Циљ предвиђања (прогнозирања) јесте процена будућих вредности, које означавамо са $\hat{y}_{T+h}$ за $h = 1, 2, \dots, H$, где h представља хоризонт предвиђања, на основу историјских података и потенцијалних екстерних фактора [10].

Иако класична теорија временских серија често посматра податке кроз експлицитне декомпозиције на тренд, сезоналност и шум, у савременим предиктивним системима, моделима се најчешће прослеђује сирова, недекомпована серија. Без обзира на то да ли припадају фамилији статистичких метода, алгоритмима машинског учења, или архитектурама дубоког учења, од модела се очекује да самостално екстрахују релевантне темпоралне инфор-

мације директно из оригиналног сигнала.

У контексту ланаца снабдевања, посебан изазов представљају подаци на најнижим нивоима агрегације који некада попримају облик **испрекиданих (интермитентних) временских серија**. Испрекидане серије карактерише велики број нултих вредности (периоди без икакве потражње) испрекидан повременим, често варијабилним позитивним вредностима када се потражња заправо деси.

Управо ово својство чини предвиђање серија изузетно тешким и подложним високом нивоу шума, што потенцијално можемо решити позајмљивањем стабилнијих информација са виших нивоа агрегације кроз процес хијерархијског усклађивања (где се скуп индивидуалних серија y_t третира као јединствен мултиваријантни систем $\mathbf{y}_t$), како би се побољшале предикције на целом систему.

2.2 Хијерархијске и груписане временске серије

У реалним пословним системима, временске серије нису изоловани ентитети, већ су међусобно повезане строгим правилима агрегације. Ове структуре се генерално деле на хијерархијске (где постоји строги редослед рапчлањивања, нпр. Држава $\rightarrow$ Регион $\rightarrow$ Град) и груписане (где се подаци могу агрегирати по више независних атрибута, нпр. агрегација по географској локацији или алтернативно по типу производа).

Математичка формулација структуралних хијерархија

Нека систем садржи укупно n временских серија, од којих се m серија налази на најнижем (базном) нивоу, док преосталих $k = n - m$ серија представљају агрегиране вредности на вишим нивоима.

Вектор свих опсервација у тренутку t , означен са $\mathbf{y}_t$ (димензија $n \times 1$), може се партиционисати на вектор агрегираних серија $\mathbf{a}_t$ (димензија $k \times 1$) и вектор базних серија $\mathbf{b}_t$ (димензија $m \times 1$):

$$\mathbf{y}_t = \begin{bmatrix} \mathbf{a}_t \\ \mathbf{b}_t \end{bmatrix} \quad (2.1)$$

Кључни алгебарски елемент који дефинише структуру овог система јесте **матрица сабирања $\mathbf{S}$** (енгл. *summing matrix*) димензија $n \times m$. Ова матрица мапира базне серије у све остале серије у систему. Коришћењем матрице $\mathbf{S}$, цео систем се може изразити искључиво преко базних серија:

$$\mathbf{y}_t = \mathbf{S}\mathbf{b}_t \quad (2.2)$$

Матрица $\mathbf{S}$ се може партиционисати као:

$$\mathbf{S} = \begin{bmatrix} \mathbf{A} \\ \mathbf{I}_m \end{bmatrix} \quad (2.3)$$

где је $\mathbf{A}$ агрегациона матрица димензија $k \times m$ која дефинише како се базне серије сабирају да би се добили виши нивои, док је $\mathbf{I}_m$ јединична матрица димензија $m \times m$ која мапира базне серије саме на себе. Елементи матрице $\mathbf{A}$ су типично бинарни (0 или 1), где 1 означава да базна серија припада одговарајућем агрегираном чвору.

Да би се илустровала моћ и флексибилност ове формулације, у наставку су приказана два карактеристична примера: један за стриктну хијерархију и један за груписане серије.

Пример 1: Стриктна хијерархија (Дрво)

Посматрајмо систем са три нивоа, где је укупна продаја државе (највиши ниво, y_T) декомпонована на два региона: Север (y_S) и Југ (y_J). Даље, регион Север чине два града (y_{S1}, y_{S2}), а регион Југ такође два града (y_{J1}, y_{J2}). Ово је класична структура стабла где су нижи нивои стриктни подскупови виших.

У овом систему имамо $m = 4$ базне серије (градови) и укупно $n = 7$ серија. Матрица сабирања $\mathbf{S}$ димензија 7×4 формира се на следећи начин:

$$\begin{bmatrix} y_T \\ y_S \\ y_J \\ y_{S1} \\ y_{S2} \\ y_{J1} \\ y_{J2} \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{\mathbf{S}} \begin{bmatrix} y_{S1} \\ y_{S2} \\ y_{J1} \\ y_{J2} \end{bmatrix} \quad (2.4)$$

Горња три реда представљају агрегациону матрицу $\mathbf{A}$, док су доња четири реда јединична матрица $\mathbf{I}_4$.

Пример 2: Груписане временске серије

За разлику од стриктне хијерархије, подаци се често могу груписати по више независних атрибута. Претпоставимо да компанија прати продају по географском региону (Регион А и Регион Б) и алтернативно по категорији производа (Производ Х и Производ Y).

Најнижи (базни) ниво чине све комбинације ових атрибута ($y_{AX}, y_{AY}, y_{BX}, y_{BY}$), што даје $m = 4$. Виши нивои чине: укупна продаја (y_T), укупна продаја по регионима (y_A, y_B) и укупна продаја по производима (y_X, y_Y). Укупно имамо $n = 9$ серија. Матрица сабирања **S** сада изгледа овако:

$$\begin{bmatrix} y_T \\ y_A \\ y_B \\ y_X \\ y_Y \\ y_{AX} \\ y_{AY} \\ y_{BX} \\ y_{BY} \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}}_{\mathbf{S}} \begin{bmatrix} y_{AX} \\ y_{AY} \\ y_{BX} \\ y_{BY} \end{bmatrix} \quad (2.5)$$

Док редови за регионе врше класично сабирање суседних елемената (као у Примеру 1), редови за производе (y_X и y_Y) врше унакрсно сабирање (нпр. $y_X = y_{AX} + y_{BX}$). Целокупна комплексност било стриктне хијерархије, било унакрсног груписања, садржана је унутар структуре матрице **S**.

Временске хијерархије

Поред структуралне агрегације, временске серије се могу посматрати кроз призму временских хијерархија [3]. Ако претпоставимо да располажемо подацима високе фреквенције, ове опсервације се могу агрегирати у ниже фреквенције. Временска хијерархија омогућава да се шум у високофреквентним подацима ублажи кроз агрегацију, док нискофреквентни подаци олакшавају моделирање дугорочних трендова.

Концепт изоморфизма између структуралних и временских хијерархија може се приказати на примеру агрегације високофреквентних **месечних по-**

датака у нискофреквентну кварталну серију (што уједно одговара и временској агрегацији примењеној у овом истраживању).

Нека су y_{M1}, y_{M2}, y_{M3} опсервације за три узастопна месеца (базне серије у временском домену), а y_{Q1} њихова укупна квартална вредност (агрегирана серија). Временски вектор система за овај квартал је $\mathbf{y}_{temp} = \begin{bmatrix} y_{Q1} & y_{M1} & y_{M2} & y_{M3} \end{bmatrix}^T$.

Припадајућа матрица сабирања $\mathbf{S}_{temp}$ димензија 4×3 формира се по идентичном принципу:

$$\begin{bmatrix} y_{Q1} \\ y_{M1} \\ y_{M2} \\ y_{M3} \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_{M1} \\ y_{M2} \\ y_{M3} \end{bmatrix} \quad (2.6)$$

Кроз ове примере јасно се уочава да без обзира на то да ли се подаци агрегирају просторно или темпорално, алгебарска структура проблема (релација $\mathbf{y} = \mathbf{S}\mathbf{b}$) остаје потпуно иста. Ово својство омогућава примену идентичних алгоритама за оптимално усклађивање како на просторној, тако и на временској димензији.

2.3 Методе за усклађивање предвиђања

Када се за сваку серију у хијерархији независно генерише предвиђање, добијамо вектор неусклађених прогноза $\hat{\mathbf{y}}_t$. Због независне природе предиктивних процеса, ове прогнозе готово никада не задовољавају хијерархијску структуру, односно:

$$\hat{\mathbf{y}}_t \neq \mathbf{S}\tilde{\mathbf{b}}_t \quad (2.7)$$

за било који вектор $\tilde{\mathbf{b}}_t$. Овај недостатак кохерентности решава се приступом усклађивања.

Општи оквир усклађивања и традиционалне методе

Све линеарне методе усклађивања могу се представити у форми пројекције независних прогноза на кохерентни потпростор. Комплетан вектор усклађених прогноза $\tilde{\mathbf{y}}_t$, који садржи ревидиране вредности за све серије на свим нивоима система, добија се линеарном трансформацијом:

$$\tilde{\mathbf{y}}_t = \mathbf{S}\mathbf{P}\hat{\mathbf{y}}_t \quad (2.8)$$

Математички посматрано, ова трансформација се одвија у два логичка корака. Прво, пројекциона матрица $\mathbf{P}$ (димензија $m \times n$) узима информације из неусклађених прогноза са свих нивоа ($\hat{\mathbf{y}}_t$) и мапира их у вектор кохерентних прогноза на основном (базном) нивоу. Затим, множењем са матрицом сабирања $\mathbf{S}$, те усклађене базне прогнозе се агрегирају. Коначни резултат ове операције ($\tilde{\mathbf{y}}_t$) јесте потпуно усклађен систем у коме су прогнозе на апсолутно свим нивоима хијерархије математички конзистентне. Иако је у пракси базни ниво најчешће примарни таргет за евалуацију предиктивних метрика и оперативну реализацију, процес усклађивања унапређује и синхронизује цео систем.

Овај алгебарски оквир је универзалан [21]. Све традиционалне, хеуристичке методе усклађивања могу се представити специфичним избором елемената унутар матрице $\mathbf{P}$:

Приступ од дна ка врху (енгл. *Bottom-Up*):

Ова метода, која представља један од најстаријих приступа у хијерархијском прогнозирању [6], претпоставља да су прогнозе на најнижем нивоу једине релевантне, док се прогнозе генерисане на вишим нивоима потпуно игноришу. Усклађене прогнозе виших нивоа добијају се искључиво сабирањем базних прогноза. Матрица $\mathbf{P}$ за ову методу дефинише се као:

$$\mathbf{P}_{BU} = \begin{bmatrix} \mathbf{0}_{m \times k} & \mathbf{I}_m \end{bmatrix} \quad (2.9)$$

где је $\mathbf{0}_{m \times k}$ нулти блок који множи и поништава све прогнозе са виших нивоа (укупно k серија), док јединична матрица $\mathbf{I}_m$ пропушта базне прогнозе непромењене.

Да бисмо ово илустровали на Примеру 1 из претходног поглавља (где имамо $n = 7$ серија и $m = 4$ града као базне серије), вектор свих неусклађених прогноза је $\hat{\mathbf{y}}_t = [\hat{y}_T, \hat{y}_S, \hat{y}_J, \hat{y}_{S1}, \hat{y}_{S2}, \hat{y}_{J1}, \hat{y}_{J2}]^T$. Матрица $\mathbf{P}_{BU}$ димензија 4×7 изгледа овако:

$$\mathbf{P}_{BU} = \left[\begin{array}{ccc|cccc} 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{array} \right] \quad (2.10)$$

Множењем $\mathbf{P}_{BU}\hat{\mathbf{y}}_t$, прве три колоне (нулти блок) потпуно елиминишу прогнозе $\hat{y}_T, \hat{y}_S, \hat{y}_J$, остављајући само четири базне прогнозе које се затим преко

матрице $\mathbf{S}$ сабирају навише. Главни недостатак овог приступа је очигледан: огромна количина информација са врха хијерархије се просто одбацује.

Приступ од врха ка дну (енгл. *Top-Down*):

Ова метода ради потпуно супротно [8]: узима у обзир искључиво прогнозу са највишег (глобалног) нивоа, док игнорише све остале. Глобална прогноза се затим дистрибуира на ниже нивое помоћу вектора историјских пропорција $\mathbf{p} = [p_1, p_2, \dots, p_m]^T$, где важи $\sum_{i=1}^m p_i = 1$. Матрица $\mathbf{P}$ за ову методу има облик:

$$\mathbf{P}_{TD} = \begin{bmatrix} \mathbf{p} & \mathbf{0}_{m \times (n-1)} \end{bmatrix} \quad (2.11)$$

Ако ово применимо на исти Пример 1 са 7 серија, и претпоставимо да смо израчунали вектор пропорција $\mathbf{p} = [p_{S1}, p_{S2}, p_{J1}, p_{J2}]^T$ (нпр. на основу просечне историјске продаје сваког града), матрица $\mathbf{P}_{TD}$ изгледа овако:

$$\mathbf{P}_{TD} = \begin{bmatrix} p_{S1} & 0 & 0 & 0 & 0 & 0 & 0 \\ p_{S2} & 0 & 0 & 0 & 0 & 0 & 0 \\ p_{J1} & 0 & 0 & 0 & 0 & 0 & 0 \\ p_{J2} & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (2.12)$$

Када ову матрицу помножимо са $\hat{\mathbf{y}}_t$, она из целог система „извлачи” искључиво једну једину вредност, глобалну прогнозу целе државе $\hat{y}_T$ (преко прве колоне), множи је са пропорцијама, док нулти блок елиминише апсолутно све остале прогнозе (укључујући регионалне и градске). Недостатак овог приступа је губитак специфичних локалних динамика, јер се све базне серије присиљавају да прате глобални образац.

Приступ из средине (енгл. *Middle-Out*):

Ова метода представља хибрид претходне две [10]. Бира се један „средњи” ниво у хијерархији. Прогнозе са тог нивоа су једине које се задржавају; све прогнозе изнад тог нивоа се елиминишу и накнадно рачунају сабирањем (као код *Bottom-Up* методе), док се прогнозе испод тог нивоа елиминишу и рачунају дистрибуцијом преко пропорција (као код *Top-Down* методе).

Ако се вратимо на наш Пример 1 ($n = 7$ серија: 1 држава, 2 региона, 4 града), претпоставимо да смо изабрали средњи ниво, **Регионе** ($\hat{y}_S, \hat{y}_J$), као референтан. Прогнозе Државе и свих 4 градова се одбацују. Потребан нам је вектор пропорција $\mathbf{p} = [p_{S1}, p_{S2}, p_{J1}, p_{J2}]^T$ који говори како се региони

деле на градове. Важи правило да се градови на северу сабирају у један ($p_{S1} + p_{S2} = 1$), а градови на југу такође у један ($p_{J1} + p_{J2} = 1$).

Матрица $\mathbf{P}_{MO}$ за овај пример изгледа овако:

$$\mathbf{P}_{MO} = \begin{bmatrix} 0 & p_{S1} & 0 & 0 & 0 & 0 & 0 \\ 0 & p_{S2} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & p_{J1} & 0 & 0 & 0 & 0 \\ 0 & 0 & p_{J2} & 0 & 0 & 0 & 0 \end{bmatrix} \quad (2.13)$$

Када ову матрицу помножимо са $\hat{\mathbf{y}}_t$, она ради две ствари истовремено: нулти блок на почетку убија прогнозу државе ($\hat{y}_T$), блок на крају убија локалне прогнозе градова ($\hat{y}_{S1}, \dots$), док се из средњег дела узимају само регионалне прогнозе ($\hat{y}_S, \hat{y}_J$) и одмах множе пропорцијама p како би се спустиле на базни ниво градова.

Иако је флексибилнији, овај метод и даље пати од фундаменталног проблема: његова $\mathbf{P}$ матрица је препуна нула. Он одбацује велики део информација (игнорише прогнозе на свим нивоима осим на том једном изабраном) и што је још важније, тешко се може применити на унакрсно груписане серије где не постоји јасан „средњи” ниво.

Кључни закључак који произилази из анализе ових матрица ($\mathbf{P}_{BU}, \mathbf{P}_{TD}, \mathbf{P}_{MO}$) јесте да традиционалне хеуристике драстично ограничавају проток информација јер намерно поништавају огроман део вектора $\hat{\mathbf{y}}_t$. То ствара математичку потребу за проналажењем **оптималне матрице $\mathbf{P}$** у којој неће бити нултих блокова, већ ће она активно комбиновати прогнозе са апсолутно свих нивоа у систему како би се минимизовала укупна грешка.

Метод минималног трага (MinT)

Савремени приступ оптималном усклађивању развили су Wickramasuriya и сарадници [21] кроз метод минималног трага (MinT). Циљ MinT алгорита је проналажење матрице $\mathbf{P}$ која минимизује траг (укупну варијансу) коваријационе матрице грешака усклађених прогноза, уз услов непристрасности ($\mathbf{P}\mathbf{S} = \mathbf{I}_m$).

Аналитичко решење овог оптимизационог проблема дато је једначином:

$$\mathbf{P} = (\mathbf{S}^T \mathbf{W}^{-1} \mathbf{S})^{-1} \mathbf{S}^T \mathbf{W}^{-1} \quad (2.14)$$

где је $\mathbf{W} = E[\mathbf{e}_t \mathbf{e}_t^T]$ коваријациона матрица грешака базних прогноза ван узорка ($\mathbf{e}_t = \mathbf{y}_t - \hat{\mathbf{y}}_t$). Заменом $\mathbf{P}$ у општу једначину, добијамо коначну MinT формулу:

$$\tilde{\mathbf{y}}_t = \mathbf{S}(\mathbf{S}^T \mathbf{W}^{-1} \mathbf{S})^{-1} \mathbf{S}^T \mathbf{W}^{-1} \hat{\mathbf{y}}_t \quad (2.15)$$

Апроксимације коваријационе матрице (MinT варијанте)

Суштински изазов MinT алгоритма лежи у чињеници да је стварна матрица $\mathbf{W}$ непозната и мора бити апроксимирана на основу резидуала из узорка (модела обуке). Дефинисаћемо пет теоријских варијанти матрице $\mathbf{W}$, од којих је четири примењено у експерименталном делу:

- **OLS (Ordinary Least Squares):** Ова метода [9] претпоставља да је $\mathbf{W} \propto \mathbf{I}_n$ (матрице су пропорционалне). Ова детерминистичка метода игнорише све корелације и разлике у варијансама између серија. Решење се ослања искључиво на топологију матрице $\mathbf{S}$.
- **WLS_Struct (Weighted Least Squares - Structural):** Предложена такође од стране Hynndman-а и сарадника [9], ова метода претпоставља да су варијансе грешака пропорционалне броју базних серија које се сабирају у одређени чвор. Матрица $\mathbf{W}$ је дијагонална: $\mathbf{W}_{struct} = \text{diag}(\mathbf{S}\mathbf{1})$, где је $\mathbf{1}$ вектор јединица. Попут OLS-а, ова метода зависи само од структуре хијерархије.
- **WLS_Var (Weighted Least Squares - Variance):** Емпиријска метода уведена кроз MinT оквир [21] која користи израчунате варијансе резидуала за дијагоналу, док вандијагоналне елементе (корелације) поставља на нулу. Ово резултује дијагоналном матрицом $\mathbf{W}_{var} = \text{diag}(\hat{\Sigma})$.
- **MinT_Sample (Класична MinT метода):** Ова метода користи пуну, нерегулисану узорачку коваријансну матрицу грешака $\mathbf{W}_{sample} = \frac{1}{T-1} \mathbf{E}^T \mathbf{E}$ (где је $\mathbf{E}$ центрирана матрица резидуала димензија $T \times n$). Ова матрица садржи стварне емпиријске варијансе и коваријансе без икаквих модификација. Иако је теоријски идеална, у пракси је подложна рачунарским сломовима у великим системима. Из тог разлога, класична варијанта није уопште могла бити извршена нити обухваћена у нашем експерименталном раду.

- **MinT_Shrink (Shrinkage estimator):** Савремено решење које омогућава примену пуне коваријансе у великим системима. Користи метод регуларизације по Schäfer-у и Strimmer-у [19] како би „скупило” нестабилну узорачку матрицу $\mathbf{W}_{sample}$ према стабилној дијагоналној матрици $\mathbf{W}_{var}$. Савремене софтверске имплементације [16] израчунавају овај метод кроз нумеричке пречице без експлицитног креирања комплетне коваријансне матрице у меморији, чиме се избегава појава рачунарских сломова.

Из ових разлога, класична варијанта није уопште могла бити извршена нити обухваћена у нашем експерименталном раду.

Пример израчунавања усклађених прогноза кроз 4 методе:

Да бисмо потпуно демистификовали процес размене информација кроз хијерархију, приказаћемо како се из матрица $\mathbf{W}$ добија коначна једначина за усклађену прогнозу Региона А ($\tilde{y}_A$) у нашем систему од 3 серије (y_T, y_A, y_B).

Општа једначина за пројекциону матрицу је $\mathbf{P} = (\mathbf{S}^T \mathbf{W}^{-1} \mathbf{S})^{-1} \mathbf{S}^T \mathbf{W}^{-1}$, при чему је матрица сабирања $\mathbf{S} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$.

1. OLS метода:

Користи се јединична матрица $\mathbf{W}_{ols} = \mathbf{I}_3$. Када се ово уврсти, добијамо $\mathbf{P}_{ols} = (\mathbf{S}^T \mathbf{S})^{-1} \mathbf{S}^T$. Израчунавањем ове инверзије добијамо матрицу димензија 2×3 :

$$\mathbf{P}_{ols} = \begin{bmatrix} \frac{1}{3} & \frac{2}{3} & -\frac{1}{3} \\ \frac{1}{3} & -\frac{1}{3} & \frac{2}{3} \end{bmatrix} \quad (2.16)$$

Множењем првог реда ове матрице са вектором неусклађених прогноза $\hat{\mathbf{y}}_t = [\hat{y}_T, \hat{y}_A, \hat{y}_B]^T$, добијамо коначну прогнозу за Регион А:

$$\tilde{y}_A = \frac{1}{3} \hat{y}_T + \frac{2}{3} \hat{y}_A - \frac{1}{3} \hat{y}_B \quad (2.17)$$

Видимо да усклађена прогноза задржава 66% сопственог сигнала, а позајмљује 33% информација са вишег нивоа, уз корекцију на основу суседног региона. Тежине су стриктно геометријске.

2. WLS_Struct метода:

Као што је претходно дефинисано, ова метода претпоставља да је структурна

варијанса чвора пропорционална броју базних серија које се у њему сабирају. То се алгебарски израчунава множењем матрице $\mathbf{S}$ вектором јединица $\mathbf{1}$ димензија $m \times 1$ (у нашем случају 2×1 јер имамо две базне серије):

$$\mathbf{S}\mathbf{1} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 1 \end{bmatrix} \quad (2.18)$$

Ово значи да укупна продаја (y_T) у себи садржи 2 базне серије (па јој је тежина 2), док су y_A и y_B саме по себи базне (па им је тежина 1). Постављањем ових вредности на дијагоналу добијамо $\mathbf{W}_{struct} = \text{diag}(2, 1, 1)$, па је њена инверзија $\mathbf{W}^{-1} = \text{diag}(\frac{1}{2}, 1, 1)$.

Множењем $(\mathbf{S}^T \mathbf{W}^{-1} \mathbf{S})$ добијамо $\begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 1.5 \end{bmatrix}$. Инверзијом ове матрице и множењем са $\mathbf{S}^T \mathbf{W}^{-1}$ добијамо нову пројекцију:

$$\mathbf{P}_{struct} = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} & -\frac{1}{4} \\ \frac{1}{4} & -\frac{1}{4} & \frac{3}{4} \end{bmatrix} \quad (2.19)$$

Коначна прогноза сада гласи:

$$\tilde{y}_A = \frac{1}{4}\hat{y}_T + \frac{3}{4}\hat{y}_A - \frac{1}{4}\hat{y}_B \quad (2.20)$$

У поређењу са OLS-ом, сопствени сигнал базног нивоа је појачан (са 66% на 75%), док је утицај укупне продаје ($\hat{y}_T$) смањен. Разлог је то што структурална метода математички препознаје да се чвор y_T састоји од више серија, па му додељује већу варијансу (мању поузданост у односу на директну прогнозу самог региона).

3. WLS_Var метода:

Овде уводимо емпиријске варијансе: $\mathbf{W}_{var} = \text{diag}(\hat{\sigma}_T^2, \hat{\sigma}_A^2, \hat{\sigma}_B^2)$. Да бисмо поједноставили запис, уведемо тежине (пондере) као реципрочну вредност варијансе: $w_i = 1/\hat{\sigma}_i^2$. Аналитичким решавањем матричних једначина, фактор за Регион А поприма следећи облик:

$$\tilde{y}_A = \frac{w_A(w_T + w_B)}{D}\hat{y}_A + \frac{w_T w_B}{D}\hat{y}_T - \frac{w_T w_B}{D}\hat{y}_B \quad (2.21)$$

где је $D = w_T w_A + w_T w_B + w_A w_B$ заједнички именилац. Ова формула осликава механизам емпиријске регуларизације. Наиме ако глобални модел на врху прави огромне грешке (варијанса $\hat{\sigma}_T^2 \rightarrow \infty$, па тежина $w_T \rightarrow 0$), фактори уз $\hat{y}_T$

и $\hat{y}_B$ постају нула, и систем одлучује да верује искључиво базном моделу ($\tilde{y}_A = \hat{y}_A$). Обрнуто, ако је глобални модел изузетно прецизан (мала варијанса), алгоритам му даје приоритет и снажније коригује базне серије.

4. MinT_Sample метода:

Ова метода користи пуну, нерегулисану коваријансну матрицу $\mathbf{W}_{sample}$. За разлику од претходних метода где је матрица била дијагонална, овде вандијагонални елементи (коваријансе, нпр. $\hat{\sigma}_{A,B}$) нису нуле. Због тога инверзија $\mathbf{W}_{sample}^{-1}$, као и финална матрица $\mathbf{P}_{sample} = (\mathbf{S}^T \mathbf{W}_{sample}^{-1} \mathbf{S})^{-1} \mathbf{S}^T \mathbf{W}_{sample}^{-1}$ постају потпуно густе матрице чији сваки елемент представља сложену функцију свих варијанси и коваријанси у систему.

Једначина за усклађену прогнозу Региона А у овом случају има облик:

$$\tilde{y}_A = \alpha \hat{y}_A + \beta \hat{y}_T + \gamma \hat{y}_B \quad (2.22)$$

где тежине α, β, γ сада зависе од корелације грешака. На пример, ако модели за Регион А и Регион Б конзистентно праве грешке у истом смеру (имају позитивну коваријансу $\hat{\sigma}_{A,B} > 0$), алгоритам то препознаје и користи информацију о величини грешке из Региона Б да додатно „калибрује” прогнозу Региона А пре него што их усклади. За наш мали систем ($n = 3$), ова метода савршено функционише. Међутим, због масивног преплитања свих параметара, у великим системима ($n \gg T$) ова густа матрица постаје сингуларна и њене тежине α, β, γ се математички не могу израчунати.

5. MinT_Shrink метода:

Како би задржала предности коваријанси из *MinT_Sample* методе, али избегла њен сингуларитет, ова метода уводи параметар скупљања $\lambda \in (0, 1)$. Коначна пројекциона матрица се рачуна коришћењем линеарне комбинације:

$$\mathbf{W}_{shrink} = (1 - \lambda) \mathbf{W}_{sample} + \lambda \mathbf{W}_{var} \quad (2.23)$$

Усклађена прогноза $\tilde{y}_A$ која произилази из ове матрице представља перфектан компромис између Методе 3 (*WLS_Var*) и Методе 4 (*MinT_Sample*). Вандијагонални елементи (коваријансе) из узорачке матрице се множе са $(1 - \lambda)$ чиме им се вештачки смањује утицај (скупљају се ка нули), док се стабилне варијансе на дијагонали појачавају. Алгоритам оптимално бира λ тако да систем научи унакрсне корелације између серија (нпр. између региона), али да матрица истовремено остане довољно дијагонална да би се гарантовала њена успешна инверзија у оптимизационом процесу.

Рачунарски изазови, нумеричка стабилност и проблем ненегативности

Иако алгебарски оквир MinT усклађивања нуди елегантно теоријско решење, његова примена на реалне, високодимензионалне пословне системе открива низ критичних математичких и инжењерских ограничења. Ови изазови диктирају изводљивост алгоритама у пракси и обликују методологију овог рада.

Проблем сингуларитета и прекорачења меморије (OOM)

Први суштински изазов јавља се при покушају процене пуне коваријационе матрице $\mathbf{W}_{sample}$ (класични MinT). Као што истичу Wickramasuriya и сарадници [21], када је број серија n значајно већи од броја историјских тренутака T (што је правило у ланцима снабдевања), ранг ове $n \times n$ матрице је ограничен на T . Пошто је $T \ll n$, матрица је строго дефицитарног ранга (сингуларна) и њена инверзија математички не постоји.

Поред математичке немогућности, постоји и физичко ограничење рачунарских система. Експлицитна алокација густе коваријансне матрице димензија $n \times n$ захтева гигантске количине радне меморије (често десетине гигабајта). Ово моментално доводи до грешке прекорачења меморије (енгл. *Out-of-Memory* - *OOM*) и пада система. За разлику од ње, детерминистичке и дијагоналне методе (OLS, WLS) немају овај проблем јер се у меморији чувају само као 1D низови (дијагонале) и задржавају пун ранг. Метод *MinT_Shrink* успешно заобилази OOM проблем јер се, захваљујући регуларизацији и оптимизованим имплементацијама, комплетан поступак извршава директно над „уском” матрицом резидуала $\mathbf{E}$ димензија $T \times n$, са минималним меморијским захтевима.

Проблем ненегативности и Cholesky декомпозиције

Други, једнако важан изазов произилази из чињенице да основна формулација MinT алгорита представља неограничену линеарну оптимизацију. Примена овакве трансформације често генерише негативне усклађене прогнозе ($\tilde{y}_{i,t} < 0$), што је у контексту пословне тражње физички немогуће и негативно утиче на метрике перформанси.

Теоријски, овај проблем се решава увођењем формалних ограничења ненегативности ($\tilde{\mathbf{y}}_t \geq \mathbf{0}$), што аналитичко решење MinT једначине претвара

у проблем квадратног програмирања (енгл. *Quadratic Programming* - *QP*). Међутим, примена QP решавача (енгл. *solvers*) захтева итеративну инверзију и факторизацију матрица, најчешће коришћењем Cholesky декомпозиције ($\mathbf{P} = \mathbf{L}\mathbf{L}^T$). Да би се ова декомпозиција извршила, пројекциона матрица мора бити позитивно семидефинисана.

У пракси, на реалним скуповима података са високим степеном интермитентности, матрице изведене из емпиријских резидуала ($\mathbf{W}_{var}$ и $\mathbf{W}_{shrink}$) често постају лоше кондициониране. То доводи до губитка строге позитивне семидефинитности у међукорацима оптимизације, изазивајући нумерички слом и отказ алгоритма. За разлику од њих, детерминистичке методе (OLS, WLS_Struct), чије матрице тежина зависе само од стабилне структуре хијерархије, успешно конвергирају у QP окружењу.

Компромис кроз хеуристичко одсецање (Clipping)

Као практична алтернатива формалној оптимизацији код рачунарски нестабилних емпиријских матрица, у овом раду се примењује стратегија хеуристичког одсецања вредности на нулу (енгл. *clipping to zero*). Овде се, након примене стандардне неограничене MinT једначине, свака вредност $\tilde{y}_{i,t} < 0$ експлицитно мапира у 0. Иако овај захват нарушава савршену кохерентност збирова унутар матрице $\mathbf{S}$, он отвара питање: да ли се вредност хијерархијског усклађивања налази искључиво у савршеној математичкој кохерентности, или у чињеници да метод (непосредно пре одсецања) успешно врши трансфер стабилних информација из виших нивоа ка базном нивоу.

Глава 3

Дизајн истраживања и методологија

3.1 Методолошки оквир истраживања

Ово поглавље описује експериментални оквир коришћен за испитивање утицаја хијерархијског усклађивања на тачност предвиђања временских серија. Методологија је пројектована тако да истовремено задовољи два захтева: да остане математички доследна формалном оквиру усклађивања дефинисаном у претходном поглављу, а са друге стране, да буде изводљива над реалним, високодимензионим и интермитентним подацима из пословног окружења. Због тога се посебна пажња посвећује конструкцији хијерархије, стратегији валидације, избору предиктивних модела, начину процене резидуала и постпроцесирању прогноза које нарушавају природно ограничење ненегативности.

3.2 Карактеристике и припрема скупа података

Анализа је спроведена над приватним подацима компаније Bosch из домена тржишта резервних делова за аутомобилску индустрију. Посматрани регион је Северна Америка, а временска фреквенција оригиналних података је месечна. Скуп података покрива период од 2020. до 2025. године (5 година историјских података) уз истовремено задржавање типичних ограничења ре-

алних пословних система: променљив интензитет потражње и значајан број ретких производа.

Базни ниво хијерархије дефинисан је комбинацијом три идентификационе колоне:

$$\text{ts_id} = (\text{material}, \text{customer}, \text{location}). \quad (3.1)$$

Другим речима, свака базна временска серија представља месечну потражњу за једну комбинацију материјала, купца и локације. У имплементацији се ове три колоне спајају у јединствени идентификатор серије, означен са `ts_id`. Након филтрирања задржано је приближно 20.000 конзистентних базних серија. Под конзистентношћу се подразумева да је свака серија довољно дуга, да се може једнозначно мапирати у све посматране агрегационе нивое и да не нарушава алгебарску структуру матрице сабирања $\mathbf{S}$ у посматраном временском периоду (2020. - 2025.).

Нека је $y_{i,t}$ вредност потражње за базну серију i у месецу t . За сваки временски тренутак формира се вектор базних вредности

$$\mathbf{b}_t = \begin{bmatrix} y_{1,t} & y_{2,t} & \cdots & y_{m,t} \end{bmatrix}^T, \quad (3.2)$$

где је m број базних серија. Све агрегиране серије добијају се детерминистички применом матрице сабирања:

$$\mathbf{y}_t = \mathbf{S}\mathbf{b}_t. \quad (3.3)$$

Ова формулација обезбеђује да су историјске вредности потпуно кохерентне пре почетка предвиђања. На тај начин се сва некохерентност која се јавља у експерименту може приписати независно генерисаним прогнозама и накнадном поступку усклађивања, а не грешкама у припреми података.

Дизајн структурне хијерархије

Хијерархијска структура у раду није ограничена на једно стабло, већ комбинује производну хијерархију са више независних групационих погледа. Базни ниво је дефинисан комбинацијом `material`, `customer` и `location`, док се виши нивои добијају агрегацијом по појединачним пословним атрибутима.

Разматране су следеће структурне хијерархије:

- **Customer:** независна агрегација по купцу са 127 серија. Све базне серије које припадају истом купцу сабирају се у једну серију на нивоу купца.

- **Location:** независна агрегација по локацији, са 10 серија. Овај ниво групише потражњу према географској или логистичкој локацији.
- **CBF:** независна агрегација по CBF категорији, са 16 серија. Овај поглед представља пословну класификацију.
- **PH1 → PH2 → PH3:** производна хијерархија у три нивоа. За разлику од претходних групација, ови нивои имају природан угнежђени однос: PH3 представља најдетаљнији производни ниво у овој групи, са 686 серија; PH2 је његов родитељски ниво, са 396 серија; док је PH1 најагрегиранији производни ниво, са 119 серија.
- **Total:** укупни ниво система, који сабира све базне серије у једну временску серију.

Природно је прво посматрати најширу доступну структурну поставку, јер она садржи све пословне погледе кроз које се потражња може агрегирати: купца, локацију, CBF класификацију, производну хијерархију и укупни ниво. Међутим, укључивање свих структурних нивоа истовремено повећава број агрегираних серија и број веза кроз које се информација размењује током усклађивања. Због тога је, поред пуне поставке, оправдано је размотрити и ужи подскуп хијерархија.

Ужа поставка обухвата нивое *Location*, *CBF*, *PH1* и *Total*. Овај избор задржава различите типове агрегационе информације: географско-логистички поглед, категоријални пословни поглед, најагрегиранији производни поглед и укупни системски ниво. Истовремено се изостављају нивои са већим бројем серија, као што су *Customer*, *PH2* и *PH3*, чиме се добија једноставнија структура за проверу осетљивости усклађивања на број укључених нивоа и густину њихових односа. На тај начин се у методолошки дизајн уводе две комплементарне поставке: пуна, која максимално користи доступну хијерархијску информацију, и редукована, која проверава понашање усклађивања када је размена информација ограничена на мањи број агрегираних погледа.

Алгебарски, сви ови нивои могу се представити истом матрицом сабирања **S**, али се њихова семантика разликује. Нивои *Customer*, *Location* и *CBF* представљају независне групације над истим базним скупом серија. То значи да једна базна серија истовремено припада једном купцу, једној локацији и једној CBF категорији, али ови атрибути не формирају међусобно угнежђено

стабло. Насупрот томе, производни нивои $RH1$, $RH2$ и $RH3$ третирају се као угнежђена производна хијерархија:

$$RH1 \rightarrow RH2 \rightarrow RH3. \quad (3.4)$$

Због тога се целокупна структура може посматрати као комбинација једне стриктне производне хијерархије и више независних груписаних хијерархија. Ако је $\mathbf{b}_t$ вектор базних серија, сваки структурни поглед дефинише сопствени блок редова у матрици $\mathbf{S}$. На пример, ред који одговара једном купцу има јединице на позицијама свих базних серија које припадају том купцу, док су остали елементи нуле. Аналогно томе, ред за једну локацију, CBF категорију или производни ниво сабира одговарајући подскуп базних серија.

Временска агрегација и режими усклађивања

Поред структурне агрегације, у анализу је укључена и временска агрегација. Оригиначне месечне серије агрегирају се на кварталну фреквенцију, означену са QS . Пошто је хоризонт месечног предвиђања $H = 6$, одговарајући квартални хоризонт је $H_q = 2$. За сваку серију квартална вредност добија се сабирањем три узастопне месечне вредности:

$$y_{i,r}^{(q)} = y_{i,3r-2}^{(m)} + y_{i,3r-1}^{(m)} + y_{i,3r}^{(m)}, \quad r = 1, \dots, H_q. \quad (3.5)$$

Временска агрегација се примењује на базни ниво и на сваки структурни ниво посебно. То значи да се, поред месечних серија на свим нивоима посматрају и њихове кварталне верзије. Међутим, временско усклађивање није спроведено као једно заједничко структурно-временско усклађивање над свим нивоима истовремено. Уместо тога, сваки попречни пресек хијерархије усклађује се одвојено са својом кварталном верзијом. За сваки ниво формира се засебан временски систем у ком вектор прогноза садржи кварталне и месечне прогнозе исте серије:

$$\hat{\mathbf{y}}_i = \begin{bmatrix} \hat{\mathbf{y}}_i^{(q)} \\ \hat{\mathbf{y}}_i^{(m)} \end{bmatrix}. \quad (3.6)$$

Матрица сабирања у овом случају описује само временску везу између месечних и кварталних корака. За хоризонт од шест месеци и два квартала

она има облик:

$$\mathbf{S}_{\text{temp}} = \begin{bmatrix} 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}. \quad (3.7)$$

Прва два реда представљају кварталне агрегате, док последњих шест редова представљају месечне вредности. За сваки појединачни ниво и сваку серију временско усклађивање се зато своди на пројекцију независних месечних и кварталних прогноза у простор дефинисан овом матрицом.

Потпуно заједничко структурно-временско усклађивање разматрано је као проширење ове поставке. У том случају би једна матрица сабирања $\mathbf{S}_{\text{joint}}$ истовремено садржала структурне односе између базног нивоа и агрегата, као и временске односе између месечних и кварталних прогноза. Формално, колоне такве матрице одговарале би базним месечним величинама, док би редови обухватили:

- месечне вредности на базном нивоу;
- месечне вредности на свим структурним агрегатима;
- кварталне вредности на базном нивоу;
- кварталне вредности на свим структурним агрегатима.

Међутим, ова формулација је у посматраном систему довела до проблема прекорачења радне меморије. Разлог је у томе што се број чворова у заједничком систему не повећава линеарно само бројем серија, већ и бројем временских корака и бројем структурних погледа. На пример, ако је број базних серија приближно $m = 20.000$, а месечни хоризонт $H = 6$, број колона заједничке матрице сабирања одговара броју базних месечних величина:

$$mH = 20.000 \cdot 6 = 120.000. \quad (3.8)$$

Број редова је већи, јер обухвата све величине које се изражавају преко базних месечних вредности: базне месечне прогнозе, базне кварталне прогнозе,

структурне месечне агрегате и структурне кварталне агрегате. Приближно, овај број износи 170.000. Због тога заједничка матрица сабирања има ред величине

$$\mathbf{S}_{\text{joint}} \in \mathbb{R}^{170.000 \times 120.000}. \quad (3.9)$$

Ова процена не укључује додатне матрице које настају током MinT пројекције, факторизације или процене коваријанси, па би стварни меморијски захтев био још већи. Због тога је заједничко структурно-временско усклађивање искључено из финалног експерименталног извршавања. Уместо њега, примењена су два рачунарска изводљива режима: структурно усклађивање на истој фреквенцији и временско усклађивање појединачно за сваки попречни пресек. Овај избор задржава могућност анализе оба механизма преноса информација, али избегава експлицитну конструкцију огромне заједничке матрице која није изводљива на расположивим ресурсима.

3.3 Поставка и процес спровођења експеримента

Стратегија тренирања, валидације и оптимизације хиперпараметара

Полазна тачка експерименталне поставке је хронолошка подела података на тренинг и тест период. Сви модели се обучавају искључиво на историјским опсервацијама које претходе тест периоду, док је последњих шест месеци посматраног периода издвојено за коначну евалуацију. На тај начин се симулира реалан сценарио прогнозирања, у ком модел у тренутку обучавања нема приступ будућим вредностима. Ова поставка одговара стратегији валидације ван узорка (енгл. *out-of-sample*). Хоризонт предвиђања је зато $H = 6$.

За оптимизацију хиперпараметара, тренинг скуп се додатно дели на интерни скуп за обучавање и валидациони прозор. Валидациони прозор дефинисан је као последњих шест месеци тренинг скупа, чиме се симулира исти тип задатка као у коначном тестирању, али без коришћења информација из тест периода. Оптимизација хиперпараметара спроводи се као бајесовска оптимизација над унапред дефинисаним просторима претраге. За сваку ком-

бинацију модела и нивоа хијерархије покреће се ограничен број покушаја, при чему је у експерименталној конфигурацији број покушаја постављен на 10.

Због великог броја базних серија и високих трошкова обучавања, оптимизација хиперпараметара се само на базном нивоу спроводи над подузорком од 10% серија. На агрегираним нивоима користи се пун скуп серија, јер је број серија на тим нивоима значајно мањи и рачунарски изводљив за директну оптимизацију. Овај приступ представља компромис између репрезентативности и рачунарске захтевности.

Критеријум оптимизације је WAPE на валидационом прозору:

$$\text{WAPE} = \frac{\sum_{i,t} |y_{i,t} - \hat{y}_{i,t}|}{\sum_{i,t} |y_{i,t}| + \varepsilon}, \quad (3.10)$$

где је ε мала позитивна константа која спречава дељење нулом код серија са изузетно ретком потражњом.

Након избора најбоље комбинације хиперпараметара, модел се поново обучава над целокупним тренинг скупом одговарајућег нивоа хијерархије, односно над свим опсервацијама које претходе тест периоду. Овим кораком се избегава губитак информација који би настао када би финални модел остао обучен само на интерном НРО тренинг подскупу. Дакле, валидациони прозор служи за избор хиперпараметара, али се након тог избора подаци из тог прозора враћају у тренинг скуп за финално обучавање модела.

Код модела дубоког учења задржава се посебан део тренинг скупа за праћење вредности функције губитка током обучавања. Овај део не представља коначни тест скуп, већ интерни валидациони сигнал који омогућава праћење стабилности обучавања, рано заустављање и контролу прекомерног прилагођавања. На тај начин се код неуронских модела раздвајају три улоге података: тест период за коначну евалуацију, НРО валидациони прозор за избор хиперпараметара и интерни валидациони сигнал током самог обучавања.

Тако добијени финални модел затим генерише прогнозу за наредних $H = 6$ месеци:

$$\hat{\mathbf{y}}_{T+1:T+H}. \quad (3.11)$$

Ове прогнозе се, у зависности од експерименталног режима, или директно евалуирају као неусклађене прогнозе или прослеђују поступку хијерархијског усклађивања.

Предиктивни модели

Статистички модели

Прву групу сачињавају класични униваријантни статистички модели. Њихова основна карактеристика је локални приступ, што значи да се параметри модела оптимизују потпуно независно за сваку појединачну временску серију:

- **AutoARIMA**: Коришћењем алгоритма из библиотеке `pmdarima`, за сваку серију се аутоматски идентификује оптимална структура модела на основу информационих критеријума. Код овог модела уведен је резервни механизам за случајеве нумеричких отказа, попут немогућности конвергенције оптимизационог алгоритма код изузетно интермитентних серија. Уколико алгоритам откаже, за ту серију се локално додељује последња посматрана вредност ($\hat{y}_{i,T+h} = y_{i,T}$), чиме се спречава прекид рада и осигурава потпуна покривеност система.
- **Holt-Winters (Експоненцијално равнање)**: Имплементиран преко класе `ExponentialSmoothing` из оквира `statsmodels`. С обзиром на природу података и присуство нултих вредности у интермитентним серијама, у експерименту су стриктно коришћени адитивни тренд и адитивна сезоналност, будући да мултипликативне компоненте нису математички дефинисане над серијама које садрже нуле.
- **Prophet** [20]: Имплементиран ослањањем на званичну `prophet` библиотеку. Овај алгоритам приступа проблему предвиђања кроз робусну декомпозицију на тренд и сезоналност коришћењем генерализованих адитивних модела (GAM).

Иако се статистички модели обучавају локално, њихова оптимизација (НРО) спроводи се глобално. Како би се спречило преприлагођавање (енгл. *overfitting*) локалном шуму, одређени хиперпараметри се фиксирају и заједнички оптимизују за цео ниво хијерархије.

Предност ових модела је то што су интерпретабилни, међутим, њихов фундаментални недостатак јесте то што се свака серија третира независно, па ови модели не могу да позајмљују статистичку снагу из сродних серија током процеса обучавања (енгл. *cross-learning*).

Класични модели машинског учења

Другу групу чине глобални регресиони модели засновани на ансамблима стабала одлучивања:

- **Random Forest** [4]: Имплементиран преко класе `RandomForestRegressor` из оквира `scikit-learn`. Заснива се на техници бегинга (енгл. *bagging*) независних стабала одлучивања ради смањења варијансе.
- **LightGBM** [11]: Имплементиран преко класе `LGBMRegressor` из оквира `lightgbm`. Заснива се на алгоритму појачавања градијента (енгл. *gradient boosting*) који секвенцијално гради стабла са циљем минимизације резидуалне грешке.

За разлику од статистичких модела који директно раде са временским низовима, модели засновани на стаблима захтевају трансформацију временских серија у табеларни формат. За оба модела користи се заједнички механизам конструкције карактеристика (енгл. *feature engineering*). За серију i и тренутак t , улазни вектор $\mathbf{x}_{i,t}$ садржи блок историјских вредности (енгл. *lags*) и аутоматски екстраховане календарске карактеристике:

$$\mathbf{x}_{i,t} = \left[y_{i,t-p}, \dots, y_{i,t-1}, \text{month}(t), \text{quarter}(t), \text{year}(t) \right]^T \quad (3.12)$$

где p представља максимални број лагова који је укључен у модел као хиперпараметар.

Ови модели се обучавају глобално, што значи да један јединствени модел користи улазне узорке ($\mathbf{x}_{i,t}$) из свих 20.000 серија истовремено. На тај начин, стабла одлучивања врше унакрсно учење и способна су да препознају заједничке нелинеарне обрасце тражње на нивоу целог система.

У погледу генерисања прогноза кроз време, у експерименту се испитују две алтернативне стратегије предвиђања вишеструких корака унапред:

- **Рекурзивна стратегија:** Обучава се један једнокорачни модел (модел предвиђа само $t + 1$). За хоризонте веће од 1, модел користи сопствене претходно предвиђене вредности као историјске лагове за следеће кораке.
- **Директна стратегија:** Обучава се потпуно засебан модел за сваки корак хоризонта h . Ова стратегија је рачунарски знатно захтевнија, али

избегава акумулацију грешке до које долази услед рекурзивног враћања сопствених (потенцијално нетачних) прогноза.

Модели дубоког учења

Трећу групу чине напредни глобални модели засновани на архитектурама дубоког учења (енгл. *deep learning*):

- **DeepAR** [18]: Имплементиран преко класе `DeepAREstimator` из оквира `GluonTS`. Овај алгоритам представља ауторегресивну архитектуру засновану на рекурентним неуронским мрежама (најчешће са LSTM ћелијама). Уместо да директно предвиђа будућу тачкасту вредност, мрежа у сваком временском кораку t узима скривено стање из претходног корака $\mathbf{h}_{i,t-1}$, претходну опсервацију $y_{i,t-1}$ и екстерне коваријате $\mathbf{x}_{i,t}$ (попут календарских одлика) како би проценила параметре унапред дефинисане пробабилистичке расподеле (нпр. средњу вредност μ и варијансу σ^2 код Гаусове расподеле). Предност овог приступа је што модел учи заједничке глобалне тежине мреже преко свих серија, док интерна локална скалирања омогућавају прилагођавање специфичним магнитудама тражње сваког производа. Како би се излаз овог вероватносног модела могао интегрисати са методама хијерархијског усклађивања (MinT), из генерисане прогнозне расподеле се за потребе даље оптимизације екстрахује искључиво њено математичко очекивање (средња вредност).
- **N-HITS (Neural Hierarchical Interpolation for Time Series)** [5]: Имплементиран преко `NeuralForecast` библиотеке из Nixtla екосистема. Овај модел представља најсавременију блоковску неуронску архитектуру која решава проблеме комплексности традиционалних рекурентних мрежа увођењем вишеструких стопа узорковања. Архитектура се састоји од низа узастопних слојева (блокова), од којих сваки обрађује сигнал на различитој фреквенцији. Коришћењем операција подсемпловања (енгл. *max-pooling*), почетни блокови екстрахују дугорочне, нискофреквентне трендове из улазног сигнала. Резидуална грешка се прослеђује каснијим блоковима који се фокусирају на све финије, високофреквентне локалне флукуације. Овако екстраховани сигнали са различитих скала се затим спајају помоћу интерполације (формирајући

коначну прогнозу). Осим што пружа високу интерпретабилност кроз декомпозицију сигнала, N-HITS генерише вишекорачне прогнозе директно (сви кораци хоризонта H се рачунају истовремено кроз излазни вишеслојни перцептрон), чиме се у потпуности избегава акумулација грешке карактеристична за рекурзивне ауторегресивне моделе.

Као и у случају стабала одлучивања, обе неуронске архитектуре се обучавају глобално, над свим серијама у систему истовремено.

Фундациони модели

Четврту и најсавременију групу предиктивних алгоритама у овом експерименту чине велики, претходно обучени фундаментални модели (енгл. *foundation models*):

- **Chronos (Chronos-2)** [1]: Овај алгоритам припада најновијој генерацији фундаменталних модела развијених од стране компаније Amazon. Chronos приступа предвиђању временских серија кроз призму процесирања природног језика (NLP), користећи класичну трансформер архитектуру. Нумеричке вредности временске серије се прво дискретизују у специфичне токене, чиме се проблем своди на класичан проблем класификације следећег токена у језичком моделу.
- **TimesFM (Time Series Foundation Model)** [7]: Модел развијен од стране компаније Google. За разлику од Chronos-a који вредности претвара у токене, TimesFM користи архитектуру засновану искључиво на декодеру (слично као GPT модели), уз примену технике дељења сигнала на делове (енгл. *patching*). Ова техника му омогућава да директно обрађује сирове непрекидне вредности кроз блокове података, чиме задржава високу ефикасност и брзину при раду са серијама различитих фреквенција.

За разлику од статистичких модела и модела машинског учења, фаза обучавања код фундаменталних модела не постоји у традиционалном смислу. Нема ажурирања параметара мреже нити прилагођавања тежина на специфичном скупу података. Уместо тога, фаза припреме подразумева само учитавање претходно обучених тежина модела и формирање одговарајућих контекстних

прозора (енгл. *context windows*) који садрже историјске вредности серије. Систем затим на основу тог прозора директно генерише будуће вредности.

Постпроцесирање прогноза: одсецање негативних вредности

Пошто посматрана величина представља потражњу, природно ограничење система је стриктна ненегативност ($y_{i,t} \geq 0$). Међутим, већина примењених базних модела, као и сами линеарни оператори усклађивања, не гарантују да ће излазне прогнозе остати ненегативне.

Формално увођење ограничења ненегативности претвара аналитичко MinT решење у проблем квадратног програмирања (QP). Као што је раније дискутовано, на реалним подацима са великим бројем интермитентних серија, емпиријске матрице тежина ($\mathbf{W}_{var}$ и $\mathbf{W}_{shrink}$) често постају лоше кондициониране, што током факторизације у QP решавачима изазива нумерички слом и отказ система.

Због тога је експериментални поступак хијерархијског усклађивања подељен у два правца:

1. За рачунарски стабилне детерминистичке методе (OLS и WLS_Struct), усклађивање је спроведено на два паралелна начина: коришћењем формалне QP оптимизације са ограничењима, као и коришћењем неограниченог усклађивања са накнадним хеуристичким одсецањем.
2. За све методе (укључујући нестабилне емпиријске методе WLS_Var и $MinT_Shrink$), спроведено је неограничено усклађивање након којег је примењен хеуристички постпроцесор (енгл. *clipping to zero*) који све негативне вредности мапира у нулу:

$$\tilde{y}_{i,t}^+ = \max(\tilde{y}_{i,t}, 0). \quad (3.13)$$

Оваква експериментална поставка омогућава да се у наредном поглављу егзактно упореди утицај строге математичке кохерентности (QP ограничења) у односу на једноставну пост-хок хеуристику (одсецање на нулу), као и њихов утицај на крајњу прецизност.

Критеријуми и метрике за евалуацију

Перформансе предиктивног система процењују се поређењем стварних историјских опсервација $y_{i,t}$ са свим варијантама генерисаних прогноза. Приликом избора евалуационих метрика, посебна пажња посвећена је њиховој робусности, тј. способности да се примене на серије драстично различитих размера и да остану нумерички стабилне у условима високе интермитентности и присуства нултих вредности у имениоцу.

Основна метрика коришћена током интерне оптимизације хиперпараметара (НРО), као и за примарно рангирање модела, јесте **WMAPE** (енгл. *Weighted Mean Absolute Percentage Error*):

$$\text{WMAPE} = \frac{\sum_{i,t} |y_{i,t} - \hat{y}_{i,t}|}{\sum_{i,t} |y_{i,t}| + \varepsilon}. \quad (3.14)$$

За свеобухватну финалну евалуацију на тест скупу, у раду се прати шири скуп метрика дефинисан у оквиру евалуационог модула. Нека је N укупан број тачака за које се рачуна прогноза. Метрике су дефинисане на следећи начин:

- **nRMSE (Нормализована коренска средња квадратна грешка):** Мери стандардну девијацију резидуала, нормализовану средњом вредношћу стварних опсервација како би се омогућило поређење серија различитих размера:

$$\text{nRMSE} = \frac{\sqrt{\frac{1}{N} \sum_{i,t} (y_{i,t} - \hat{y}_{i,t})^2}}{\frac{1}{N} \sum_{i,t} y_{i,t} + \varepsilon} \quad (3.15)$$

- **sMAPE (Симетрична апсолутна процентуална грешка):** Решава проблем асиметричности MAPE метрике (која пенализује позитивне грешке више него негативне) тако што у имениоцу укључује и прогнозу:

$$\text{sMAPE} = \frac{1}{N} \sum_{i,t} \frac{2|y_{i,t} - \hat{y}_{i,t}|}{|y_{i,t}| + |\hat{y}_{i,t}| + \varepsilon} \quad (3.16)$$

- **BIAS_PCT (Процентуална пристрасност):** Показује усмереност грешке, односно да ли модел на нивоу система конзистентно прецењује (позитиван bias) или потцењује (негативан bias) стварну потражњу:

$$\text{BIAS_PCT} = \frac{\sum_{i,t} (\hat{y}_{i,t} - y_{i,t})}{\sum_{i,t} y_{i,t} + \varepsilon} \quad (3.17)$$

Како би се детаљно испитао утицај сваког појединачног корака у експерименталном цевоводу, све наведене метрике се рачунају и упоређују у четири различите фазе:

1. На сировим (неусклађеним) базним прогнозама ($\hat{y}$).
2. На прогнозама усклађеним класичним неограниченим алгоритмом ($\tilde{y}$).
3. На прогнозама усклађеним уз формална QP ограничења ненегативности (за рачунарски стабилне методе).
4. На усклађеним прогнозама над којима је примењено хеуристичко одсецање негативних вредности на нулу ($\tilde{y}^+$).

Важно је прецизирати начин на који се све наведене метрике израчунавају и агрегирају у коначне вредности које се извештавају у резултатима. У овом раду примењен је приступ макро-усредњавања (енгл. *Macro-averaging*). Евалуациони модул прво израчунава све метрике независно за сваку појединачну серију i кроз задати хоризонт предвиђања. На пример, WMAPE за једну специфичну серију рачуна се као:

$$\text{WMAPE}_i = \frac{\sum_{t=T+1}^{T+H} |y_{i,t} - \hat{y}_{i,t}|}{\sum_{t=T+1}^{T+H} y_{i,t} + \varepsilon}. \quad (3.18)$$

Након израчунавања метрика на нивоу појединачних серија, коначна оцена за одређени агрегациони ниво (за дату комбинацију модела и фазе евалуације) добија се израчунавањем аритметичке средине (просека) тих вредности, уз игнорисање недефинисаних вредности:

$$\text{WMAPE}_{\text{overall}} = \frac{1}{N} \sum_{i=1}^N \text{WMAPE}_i \quad (3.19)$$

Овакав дизајн евалуације има оправдање у домену ланаца снабдевања, где за разлику од приступа глобалног сумирања (енгл. *Micro-averaging*) који интерно фаворизује серије са великим обимом продаје (које нису нужно битније), макро-усредњавање даје једнаку тежину свим серијама у систему.

Глава 4

Резултати и дискусија

У овом поглављу приказани су резултати експерименталне евалуације. Анализа је подељена у неколико логичких целина како би се систематски одговорило на истраживачка питања дефинисана у Уводу. Прво су анализирани перформансе сирових, неусклађених модела, чиме је постављена основа за мерење ефеката усклађивања. Затим је спроведена свеобухватна анализа структурног и темпоралног усклађивања, са посебним фокусом на утицај доменских ограничења (хеуристичког клипинга и формалног квадратног програмирања). На крају, квантификован је губитак математичке кохерентности, након чега су синтетизоване најбоље праксе за индустријску примену.

4.1 Анализа перформанси основних (неусклађених) предвиђања

Пре евалуације ефеката хијерархијског усклађивања, неопходно је установити апсолутне предиктивне перформансе основних модела. Резултати приказани у овом одељку служе као контролна основа у односу на коју се рачунају сва каснија маргинална побољшања или деградације. Евалуација је спроведена на најнижем, базном нивоу (приближно 20.000 временских серија).

Као што је приказано у Табели 4.1, резултати евалуације базних модела указују на изузетно велику дисперзију у тачности, при чему је најлошији модел готово осам пута непрецизнији од најбољег. Могу се издвојити два кључна обрасца:

Табела 4.1: Упоредни приказ перформанси неусклађених базних модела (сортирано по WMAPE метрици).

Базни модел	WMAPE	nRMSE	sMAPE	BIAS_PCT (%)
<i>DeepAR</i>	110.2	142.4	108.0	-4.2
<i>N-HITS</i>	113.4	143.2	116.3	6.5
<i>TimesFM</i>	118.6	147.8	112.0	15.4
<i>Chronos</i>	126.3	157.9	118.2	20.9
<i>Holt-Winters</i>	189.0	235.0	103.6	104.8
<i>Prophet</i>	190.8	228.2	103.9	103.8
<i>ARIMA</i>	192.4	217.6	106.5	120.4
<i>Random Forest</i>	301.6	318.6	106.8	249.9
<i>Random Forest (Direct)</i>	304.1	322.9	106.3	256.1
<i>LightGBM</i>	865.4	878.5	120.3	832.7
<i>LightGBM (Direct)</i>	894.0	908.0	120.5	863.8

- **Доминација дубоког учења и фундаменталних модела:** Најуспешнији предиктивни алгоритми на сировим подацима припадају фамилији неуронских мрежа. Модели *DeepAR* и *N-HITS* остварили су најбоље резултате. Изузетно је значајан и резултат фундаменталних модела, *TimesFM* и *Chronos*, који су остварили врхунске перформансе у режиму без икаквог дообучавања на специфичним подацима компаније. Овај резултат недвосмислено потврђује њихову снажну способност генерализације образаца чак и на високо интермитентним серијама.
- **Изазови примене модела заснованих на стаблима:** Модели класичног машинског учења (*LightGBM* и *Random Forest*) остварили су знатно лошије резултате, уз генерисање масивне позитивне пристрасности. Ово не индицира да су сами алгоритми инхерентно лоши, већ је директна последица њихове стандардне функције циља (MSE) која на интермитентним подацима пуним нула конзистентно предвиђа мали позитиван просек, доводећи до системског прецењивања. Поред тога, за ове моделе коришћен је релативно скроман скуп улазних карактеристика. Они намерно нису додатно прилагођавани нити обогаћивани новим подацима, будући да је један од циљева експеримента био управо да се анализира понашање и робусност алгоритама за хијерархијско усклађивање у ситуацијама када су на улазу присутне слабије и високо пристрасне базне прогнозе.

Овакав распоред снага представља идеалан полигон за тестирање MinT алгоритама, јер систем садржи како добре, робусне моделе, тако и моделе са значајније лошијим перформансама.

4.2 Упоредна анализа метода за усклађивање

У овом одељку анализира се утицај различитих метода усклађивања на прецизност базних прогноза. Резултати су подељени у зависности од тога да ли се усклађивање вршило кроз структурну (CSM) или временску (СТ) димензију.

Како би се омогућио транспарентан увид у промене свих метрика, резултати су визуелизовани кроз серију топлотних мапа које су приказане засебно за сваку димензију. Свака димензија садржи по две слике: прва приказује стабилне методе (*OLS* и *WLS_Struct*) за које је било могуће извршити сва три приступа (неограничено *reg*, хеуристичко одсецање *clip*, и формална оптимизација *qp*); друга приказује емпиријске методе (*MinT_Shrink* и *WLS_Var*) где QR приступ није приказан услед нумеричких сломова.

На овим приказима, редови означавају 11 базних предиктивних модела, док колоне представљају примењени приступ усклађивању. Свака ћелија топлотне мапе садржи две вредности: горњи број представља апсолутну разлику у односу на неусклађени базни модел, док доњи број у загради представља процентуалну промену. Негативне вредности (зелена боја) индицирају побољшање метрике након усклађивања, док позитивне вредности (црвена боја) означавају деградацију.

Структурно усклађивање (CSM)

Анализа топлотних мапа за структурну димензију (Слике 4.1 и 4.2) открива један од најважнијих налаза овог рада: **структурно усклађивање по правилу драстично деградира тачност прогноза на базном нивоу.**

Детерминистичка метода *OLS* изазива катастрофалну деградацију. На пример, код *DeerAR* модела, *OLS* у неограниченом (*reg*) режиму повећава WMAPE за екстремних +3391%, док код *Chronos* модела грешка расте за +1509%. Овакав резултат је математички очекиван у системима са 20.000 се-

ГЛАВА 4. РЕЗУЛТАТИ И ДИСКУСИЈА

CSM 3-Approach Comparison: reg vs clip vs qp (Full Hierarchy, Base Level)													
Variants with QP available green = improvement, red = degradation													
OLS		WMAPE			nRMSE			sMAPE			BIAS_PCT		
		reg	clip	qp	reg	clip	qp	reg	clip	qp	reg	clip	qp
	arima	+1968 (+1023%)	+888 (+462%)	+296 (+154%)	+2338 (+1075%)	+1216 (+559%)	+489 (+225%)	+40 (+37%)	+12 (+11%)	+59 (+55%)	-35 (-29%)	+873 (+725%)	+229 (+190%)
	chronos	+1906 (+1509%)	+1089 (+862%)	+676 (+535%)	+2081 (+1305%)	+1257 (+796%)	+845 (+535%)	+27 (+23%)	+3 (+3%)	+39 (+33%)	+291 (+1391%)	+1108 (+5305%)	+663 (+3172%)
	deepar	+275 (+3391%)	+2016 (+1830%)	+940 (+854%)	+4252 (+2987%)	+2576 (+1809%)	+1252 (+880%)	+43 (+40%)	+18 (+17%)	+53 (+49%)	+323 (+7755%)	+2042 (+49037%)	+923 (+22170%)
	holt_winters	+2045 (+1082%)	+988 (+523%)	+337 (+178%)	+2265 (+964%)	+1133 (+482%)	+420 (+179%)	+45 (+43%)	+17 (+16%)	+56 (+54%)	-81 (-77%)	+977 (+932%)	+291 (+277%)
	lightgbm	+1964 (+227%)	+729 (+84%)	+29 (+3%)	+2441 (+278%)	+1257 (+143%)	+500 (+57%)	+30 (+25%)	+5 (+5%)	+47 (+39%)	-58 (-67%)	+677 (+81%)	-73 (-9%)
	lightgbm_direct	+2207 (+247%)	+1106 (+124%)	+487 (+54%)	+2803 (+309%)	+1795 (+198%)	+955 (+105%)	+32 (+26%)	+5 (+4%)	+49 (+41%)	-54 (-6%)	+1047 (+121%)	-381 (-44%)
	nhits	+3825 (+3374%)	+1978 (+1745%)	+993 (+876%)	+4558 (+3183%)	+2915 (+2036%)	+1513 (+1111%)	+38 (+32%)	+10 (+8%)	+58 (+50%)	+150 (+2291%)	+197 (+30560%)	+953 (+14588%)
	prophet	+1943 (+1018%)	+1120 (+587%)	+743 (+389%)	+2078 (+911%)	+1224 (+536%)	+864 (+379%)	+45 (+43%)	+16 (+16%)	+60 (+58%)	+290 (+280%)	+1114 (+1073%)	+700 (+675%)
	random_forest	+2015 (+668%)	+883 (+293%)	+383 (+127%)	+2369 (+744%)	+1418 (+445%)	+787 (+247%)	+42 (+39%)	+12 (+12%)	+63 (+59%)	-208 (-83%)	+839 (+336%)	+287 (+115%)
	random_forest_direct	+2881 (+947%)	+1500 (+493%)	+845 (+278%)	+3350 (+1037%)	+1945 (+602%)	+1156 (+358%)	+45 (+42%)	+15 (+14%)	+66 (+63%)	+75 (+29%)	+1456 (+569%)	+749 (+292%)
timesfm	+2386 (+2012%)	+1381 (+1165%)	+737 (+622%)	+2585 (+1749%)	+1556 (+1053%)	+900 (+609%)	+35 (+31%)	+12 (+11%)	+46 (+41%)	+394 (+2558%)	+1399 (+9084%)	+720 (+4678%)	
WLS_struct		WMAPE			nRMSE			sMAPE			BIAS_PCT		
		reg	clip	qp	reg	clip	qp	reg	clip	qp	reg	clip	qp
	arima	+314 (+163%)	+95 (+49%)	+54 (+28%)	+384 (+177%)	+162 (+74%)	+121 (+56%)	+26 (+25%)	-0 (-0%)	+34 (+32%)	-89 (-74%)	+67 (+56%)	+10 (+9%)
	chronos	+480 (+380%)	+353 (+279%)	+331 (+262%)	+500 (+317%)	+367 (+232%)	+346 (+219%)	+5 (+4%)	-11 (-9%)	+8 (+7%)	+266 (+1271%)	+393 (+1881%)	+364 (+1744%)
	deepar	+723 (+666%)	+315 (+501%)	+107 (+462%)	+315 (+571%)	+116 (+433%)	+107 (+399%)	+10 (+16%)	+1 (+5%)	+10 (+19%)	+393 (+10023%)	+199 (+14373%)	+12 (+13126%)
	holt_winters	+410 (+217%)	+119 (+63%)	+48 (+26%)	+447 (+190%)	+144 (+61%)	+62 (+26%)	+33 (+32%)	+6 (+6%)	+42 (+40%)	-21 (-20%)	+102 (+98%)	+12 (+12%)
	lightgbm	+73 (+8%)	+126 (+15%)	+268 (+31%)	+179 (+20%)	+20 (-2%)	+173 (+18%)	+10 (+8%)	-1 (-1%)	+5 (+10%)	-356 (-43%)	+157 (+19%)	-310 (-37%)
	lightgbm_direct	-37 (-4%)	-144 (-16%)	-213 (-24%)	+65 (+7%)	-20 (-2%)	-87 (-10%)	+7 (+6%)	-3 (-3%)	+10 (+8%)	-284 (-33%)	-177 (-20%)	-253 (-29%)
	nhits	+2393 (+841%)	+1248 (+554%)	+744 (+487%)	+1842 (+784%)	+942 (+567%)	+744 (+505%)	+2 (+14%)	-2 (-2%)	+10 (+17%)	+342 (+5162%)	+169 (+10148%)	+39 (+8837%)
	prophet	+222 (+116%)	+85 (+45%)	+58 (+31%)	+234 (+102%)	+101 (+44%)	+75 (+33%)	+23 (+22%)	+2 (+2%)	+48 (+26%)	-50 (-48%)	+86 (+63%)	+48 (+46%)
	random_forest	+232 (+77%)	+34 (+11%)	-45 (-15%)	+303 (+95%)	+109 (+34%)	+112 (+7%)	+26 (+24%)	+2 (+2%)	+32 (+30%)	-208 (-83%)	-10 (-4%)	106 (+42%)
	random_forest_direct	+367 (+121%)	+177 (+58%)	+92 (+30%)	+453 (+140%)	+255 (+79%)	+167 (+52%)	+21 (+19%)	+4 (+4%)	+26 (+25%)	-44 (-17%)	+146 (+57%)	+45 (+18%)
timesfm	+552 (+466%)	+395 (+333%)	+302 (+305%)	+565 (+382%)	+402 (+272%)	+370 (+250%)	+13 (+12%)	-2 (-2%)	+16 (+14%)	+270 (+1752%)	+427 (+2775%)	+387 (+2512%)	

Слика 4.1: Структурно усклађивање (CSM): Промена перформанси након примене стабилних метода OLS и WLS_Struct кроз три различита приступа.

CSM | Reg vs Clip Only (Full Hierarchy, Base Level)
MinT_shrink & WLS_var (no QP available) | green = improvement, red = degradation

	WMAPE			nRMSE			sMAPE			BIAS_PCT		
	reg	clip	qp	reg	clip	qp	reg	clip	qp	reg	clip	qp
MinT_shrink	arima	+288 (+150%)	+145 (+76%)	+351 (+161%)	+231 (+106%)	+22 (+10%)	+7 (+3%)	+22 (+10%)	+7 (+3%)	-13 (-10%)	+130 (+108%)	+130 (+108%)
	chronos	+7 (+5%)	+5 (+4%)	+5 (+3%)	+5 (+3%)	+0 (+0%)	-8 (-7%)	+0 (+0%)	-8 (-7%)	+6 (+30%)	+8 (+37%)	+8 (+37%)
	deepar	+10 (+9%)	+8 (+7%)	+8 (+5%)	+6 (+4%)	+11 (+10%)	+1 (+1%)	+1 (+1%)	+1 (+1%)	+2 (+49%)	+4 (+99%)	+4 (+99%)
	holt_winters	-1 (-0%)	-8 (-4%)	-4 (-2%)	-9 (-4%)	-13 (-13%)	+4 (+4%)	-14 (-13%)	+4 (+4%)	-6 (-6%)	-6 (-6%)	-6 (-6%)
	lightgbm	+2162 (+192%)	+1048 (+97%)	+1048 (+193%)	+1048 (+99%)	+1048 (+40%)	+1048 (+22%)	+24 (+3%)	+24 (+3%)	+24 (+3%)	+24 (+3%)	+24 (+3%)
	lightgbm_direct	+417 (+47%)	+230 (+26%)	+417 (+46%)	+234 (+26%)	+25 (+21%)	+15 (+13%)	+15 (+13%)	+15 (+13%)	+15 (+13%)	+15 (+13%)	+15 (+13%)
	nhits	+24 (+22%)	+19 (+16%)	+23 (+16%)	+18 (+13%)	+11 (-1%)	+11 (-10%)	+11 (-10%)	+11 (-10%)	+11 (-10%)	+11 (-10%)	+11 (-10%)
	prophet	-1 (-0%)	-7 (-4%)	-4 (-2%)	-8 (-4%)	+11 (+10%)	+3 (+3%)	-11 (-11%)	+3 (+3%)	-11 (-11%)	-5 (-5%)	-5 (-5%)
	random_forest	+229 (+229%)	+90 (+90%)	+216 (+216%)	+87 (+87%)	+36 (+36%)	+15 (+15%)	-71 (-71%)	+15 (+15%)	-71 (-71%)	+8 (+8%)	+8 (+8%)
	random_forest_direct	-7 (-2%)	-10 (-3%)	-5 (-2%)	-8 (-3%)	+1 (+1%)	+0 (+0%)	-16 (-6%)	+0 (+0%)	-16 (-6%)	-13 (-5%)	-13 (-5%)
	timesfm	+7 (+6%)	+5 (+4%)	+5 (+4%)	+4 (+3%)	+4 (+4%)	+4 (+4%)	+4 (+4%)	+4 (+4%)	+4 (+4%)	+4 (+4%)	+4 (+4%)
WLS_var	arima	+18 (+9%)	+5 (+3%)	+21 (+10%)	+8 (+4%)	+1 (+1%)	-0 (-0%)	-9 (-7%)	-0 (-0%)	+4 (+3%)	+4 (+3%)	+4 (+3%)
	chronos	+7 (+5%)	+5 (+5%)	+5 (+4%)	+5 (+4%)	+0 (+0%)	-0 (-0%)	+6 (+46%)	-0 (-0%)	+10 (+47%)	+10 (+47%)	+10 (+47%)
	deepar	+7 (+6%)	+6 (+6%)	+5 (+4%)	+5 (+4%)	+11 (+10%)	+11 (+10%)	+2 (+48%)	+11 (+10%)	+2 (+48%)	+2 (+48%)	+2 (+48%)
	holt_winters	-0 (-0%)	-2 (-2%)	-1 (-1%)	-3 (-1%)	+15 (+14%)	+3 (+3%)	-7 (-7%)	+3 (+3%)	-4 (-4%)	-4 (-4%)	-4 (-4%)
	lightgbm	-120 (-14%)	-124 (-14%)	-119 (-14%)	-123 (-14%)	-1 (-1%)	-2 (-1%)	-133 (-16%)	-2 (-1%)	-133 (-16%)	-128 (-15%)	-128 (-15%)
	lightgbm_direct	-109 (-12%)	-114 (-13%)	-108 (-12%)	-113 (-12%)	-1 (-1%)	-1 (-1%)	-123 (-14%)	-1 (-1%)	-123 (-14%)	-118 (-14%)	-118 (-14%)
	nhits	+9 (+8%)	+9 (+8%)	+9 (+8%)	+9 (+8%)	-1 (-1%)	-1 (-1%)	+13 (+192%)	-1 (-1%)	+13 (+192%)	+13 (+194%)	+13 (+194%)
	prophet	+1 (+0%)	-1 (-1%)	+0 (+0%)	-1 (-1%)	+13 (+13%)	+3 (+3%)	-3 (-3%)	+3 (+3%)	-1 (-1%)	-1 (-1%)	-1 (-1%)
	random_forest	-8 (-3%)	-9 (-3%)	-8 (-2%)	-9 (-3%)	+0 (+0%)	-0 (-0%)	-12 (-5%)	-0 (-0%)	-12 (-5%)	-11 (-4%)	-11 (-4%)
	random_forest_direct	-6 (-2%)	-7 (-2%)	-6 (-2%)	-7 (-2%)	+0 (+0%)	-0 (-0%)	-10 (-4%)	-0 (-0%)	-10 (-4%)	-9 (-3%)	-9 (-3%)
	timesfm	+13 (+6%)	+6 (+6%)	+4 (+4%)	+4 (+4%)	+7 (+4%)	+6 (+3%)	+11 (+70%)	+6 (+3%)	+11 (+70%)	+11 (+70%)	+11 (+70%)

Слика 4.2: Структурно усклађивање (CSM): Промена перформанси након примене емпиријских метода MinT_shrink и WLS_var (QP оптимизација изостављена).

рија: *OLS* матрица претпоставља да све серије имају исту варијансу грешке, те слепо дистрибуира корекције са виших нивоа на ниже, потпуно уништавајући квалитетне локалне сигнале.

Примена *WLS_Struct* методе значајно ублажава ову деградацију (нпр. *WMAPE* за *DeepAR* расте за +666%), али и даље не доноси побољшање. Слично се понаша и *MinT_Shrink* метода, код које квалитетни базни модели попут *Chronos*-а и *DeepAR*-а бележе благи пад тачности (око +5% до +9%).

Једини изузетак који показује висок ниво стабилности јесте **WLS_Var** метода. Код ове методе, одлични модели задржавају своје перформансе уз минималну деградацију (нпр. *Chronos* *WMAPE* + 5%), док изразито лоши модели попут *LightGBM*-а доживљавају оштро побољшање (−14%). Овај налаз сугерише да је за успешно структурно усклађивање интермитентних података есенцијално скалирање корекција искључиво на основу историјске варијансе сваке појединачне серије, чиме се спречава преливање туђег шума на квалитетне прогнозе.

Утицај дубине хијерархије (Пуна вс. Редукована):

Додатни експеримент са редукованом структурном хијерархијом (Слика 4.3) показао је да уклањање нивоа *Customer*, *PH2* и *PH3* ублажава негативне ефекте усклађивања. На пример, деградација *ARIMA* модела при *OLS*-у пада са +1023% на +341%. Мањи број нивоа значи мањи број степени слободе и мање веза у матрици сабирања **S**, чиме се ограничава могућност алгорита да адаптира базне серије како би задовољио збирове на удаљеним нивоима.

Временско усклађивање (СТ)

За разлику од структурног усклађивања, темпорална димензија (прелазак са месечне на кварталну агрегацију) манифестује потпуно другачије обрасце понашања.

Прво, резултати за сва три приступа (*reg*, *clip*, *qp*) приказани на Слици 4.4 су идентични код темпоралног усклађивања. Ово потврђује да агрегација из месечне у кварталну фреквенцију ретко или готово никада не генерише математички негативне прогнозе, те интервенције клипинга и квадратног програмирања нису имале никакав ефекат на систем.

Друго, темпорално усклађивање генерише снажна побољшања искључиво код најлошијих модела (нпр. *LightGBM* бележи пад *WMAPE* метрике за

ГЛАВА 4. РЕЗУЛТАТИ И ДИСКУСИЈА

CSM Full vs Reduced Hierarchy (approach=reg, Base Level)									
Columns: full / subset green = improvement vs base model									
Min_T_shrink	WMAPE		nRMSE		sMAPE		BIAS_PCT		
	arima	+288 (+150%)	+27 (+14%)	+351 (+161%)	+40 (+18%)	+22 (+21%)	+6 (+6%)	-13 (-10%)	-10 (-8%)
	chronos	+7 (+5%)	+3 (+2%)	+5 (+3%)	+3 (+2%)	+0 (+0%)	+1 (+1%)	+6 (+30%)	+4 (+17%)
	deepar	+10 (+9%)	+5 (+5%)	+8 (+5%)	+3 (+2%)	+11 (+10%)	+12 (+11%)	+2 (+49%)	-4 (-92%)
	holt_winters	-1 (-0%)	-0 (-0%)	-4 (-2%)	-2 (-1%)	+13 (+13%)	+14 (+13%)	-14 (-13%)	-4 (-4%)
	lightgbm	+1662 (+192%)	+1609 (+186%)	+1699 (+193%)	+1646 (+187%)	+48 (+40%)	+48 (+40%)	-24 (-3%)	-49 (-6%)
	lightgbm_direct	+417 (+47%)	+107 (+12%)	+417 (+46%)	+109 (+12%)	+25 (+21%)	+11 (+9%)	+24 (+3%)	+60 (+7%)
	nhits	+24 (+22%)	+19 (+16%)	+23 (+16%)	+17 (+12%)	-1 (-1%)	-1 (-1%)	+22 (+33%)	+16 (+24%)
	prophet	-1 (-0%)	-4 (-0%)	-4 (-2%)	-1 (-1%)	+11 (+10%)	+12 (+12%)	-11 (-11%)	-3 (-3%)
	random_forest	+691 (+229%)	-3 (-1%)	+689 (+216%)	-3 (-1%)	+38 (+36%)	+0 (+0%)	-176 (-71%)	-6 (-2%)
	random_forest_direct	-7 (-2%)	-1 (-0%)	-5 (-2%)	-1 (-0%)	+1 (+1%)	+0 (+0%)	-16 (-6%)	-2 (-1%)
	timesfm	+7 (+6%)	+3 (+2%)	+6 (+4%)	+2 (+2%)	+4 (+4%)	+5 (+4%)	+6 (+36%)	+3 (+18%)
	full	subset	full	subset	full	subset	full	subset	
OLS	WMAPE		nRMSE		sMAPE		BIAS_PCT		
	arima	+1968 (+1023%)	+657 (+341%)	+2338 (+1075%)	+776 (+357%)	+40 (+37%)	+34 (+32%)	-35 (-29%)	+182 (+151%)
	chronos	+1906 (+1509%)	+1017 (+805%)	+2061 (+1305%)	+1072 (+679%)	+27 (+23%)	+16 (+13%)	+291 (+1391%)	+265 (+1266%)
	deepar	+3135 (+3391%)	+1922 (+1745%)	+4252 (+2987%)	+2224 (+1562%)	+43 (+40%)	+23 (+22%)	+23 (+775%)	+368 (+9349%)
	holt_winters	+2045 (+1082%)	+664 (+352%)	+2265 (+964%)	+717 (+305%)	+45 (+43%)	+39 (+37%)	-81 (-77%)	+225 (+215%)
	lightgbm	+1964 (+227%)	+549 (+63%)	+2441 (+278%)	+735 (+84%)	+30 (+25%)	+13 (+11%)	-558 (-67%)	-516 (-62%)
	lightgbm_direct	+2207 (+247%)	+725 (+81%)	+2803 (+309%)	+1040 (+115%)	+32 (+26%)	+18 (+15%)	-54 (-6%)	-54 (-6%)
	nhits	+825 (+3374%)	+1016 (+1425%)	+1588 (+3183%)	+1602 (+314%)	+36 (+32%)	+24 (+20%)	+150 (+2291%)	+368 (+8953%)
	prophet	+1943 (+1018%)	+1011 (+530%)	+2078 (+911%)	+1048 (+459%)	+45 (+43%)	+33 (+32%)	+290 (+280%)	+453 (+436%)
	random_forest	+2015 (+668%)	+938 (+311%)	+2369 (+744%)	+735 (+346%)	+42 (+39%)	+33 (+31%)	-208 (-83%)	-94 (-37%)
	random_forest_direct	+2881 (+947%)	+1342 (+441%)	+3350 (+1037%)	+1562 (+484%)	+45 (+42%)	+32 (+30%)	+75 (+29%)	+327 (+128%)
	timesfm	+2386 (+2012%)	+968 (+816%)	+2405 (+1749%)	+1063 (+720%)	+35 (+31%)	+19 (+17%)	+394 (+2558%)	+339 (+2201%)
	full	subset	full	subset	full	subset	full	subset	
WLS_struct	WMAPE		nRMSE		sMAPE		BIAS_PCT		
	arima	+314 (+163%)	+183 (+95%)	+384 (+177%)	+219 (+100%)	+26 (+25%)	+27 (+25%)	-89 (-74%)	-9 (-7%)
	chronos	+480 (+380%)	+501 (+297%)	+500 (+317%)	+501 (+213%)	+5 (+4%)	+1 (+1%)	+266 (+1271%)	+516 (+2470%)
	deepar	+733 (+666%)	+751 (+682%)	+813 (+571%)	+797 (+560%)	+17 (+16%)	+12 (+13%)	+417 (+10023%)	+684 (+16418%)
	holt_winters	+410 (+217%)	+229 (+121%)	+447 (+190%)	+243 (+104%)	+33 (+32%)	+36 (+35%)	-21 (-20%)	+44 (+42%)
	lightgbm	+73 (+8%)	-125 (-14%)	+179 (+20%)	-47 (-5%)	+10 (+8%)	+7 (+6%)	-356 (-43%)	-335 (-40%)
	lightgbm_direct	-37 (-4%)	-119 (-13%)	+65 (+7%)	-46 (-5%)	+7 (+6%)	+3 (+2%)	-284 (-33%)	-230 (-27%)
	nhits	+953 (+841%)	+674 (+594%)	+1123 (+784%)	+740 (+517%)	+16 (+14%)	+5 (+4%)	+337 (+5162%)	+670 (+10259%)
	prophet	+222 (+116%)	+119 (+62%)	+234 (+102%)	+131 (+58%)	+23 (+22%)	+18 (+17%)	-50 (-48%)	-0 (-0%)
	random_forest	+232 (+77%)	+128 (+43%)	+303 (+95%)	+194 (+61%)	+26 (+24%)	+31 (+29%)	-208 (-83%)	-116 (-46%)
	random_forest_direct	+367 (+121%)	+184 (+60%)	+453 (+140%)	+233 (+72%)	+21 (+19%)	+16 (+15%)	-44 (-17%)	-42 (-16%)
	timesfm	+552 (+466%)	+401 (+389%)	+555 (+382%)	+401 (+312%)	+13 (+12%)	+6 (+5%)	+210 (+1752%)	+487 (+3160%)
	full	subset	full	subset	full	subset	full	subset	
WLS_var	WMAPE		nRMSE		sMAPE		BIAS_PCT		
	arima	+18 (+9%)	+1 (+0%)	+21 (+10%)	+1 (+0%)	+1 (+1%)	+1 (+0%)	-9 (-7%)	-2 (-2%)
	chronos	+3 (+5%)	+3 (+2%)	+5 (+4%)	+2 (+2%)	+0 (+0%)	+1 (+1%)	+46 (+46%)	+18 (+18%)
	deepar	+7 (+6%)	+3 (+2%)	+5 (+4%)	+2 (+1%)	+11 (+10%)	+12 (+11%)	+2 (+48%)	-4 (-94%)
	holt_winters	-0 (-0%)	-0 (-0%)	-1 (-1%)	-1 (-0%)	+15 (+14%)	+15 (+14%)	-7 (-7%)	-2 (-2%)
	lightgbm	-120 (-14%)	-20 (-2%)	-119 (-14%)	-19 (-2%)	-1 (-1%)	-0 (-0%)	-133 (-16%)	-21 (-3%)
	lightgbm_direct	-109 (-12%)	-24 (-3%)	-108 (-12%)	-24 (-3%)	-1 (-1%)	+0 (+0%)	-123 (-14%)	-27 (-3%)
	nhits	+9 (+8%)	+5 (+4%)	+8 (+6%)	+5 (+3%)	-1 (-1%)	+0 (+0%)	+13 (+192%)	+7 (+100%)
	prophet	+1 (+0%)	+0 (+0%)	+0 (+0%)	-0 (-0%)	+13 (+13%)	+13 (+13%)	-3 (-3%)	-1 (-1%)
	random_forest	-8 (-3%)	-3 (-1%)	-8 (-2%)	-2 (-1%)	+0 (+0%)	+0 (+0%)	-12 (-5%)	-4 (-2%)
	random_forest_direct	-6 (-2%)	-1 (-0%)	-6 (-2%)	-1 (-0%)	+0 (+0%)	+0 (+0%)	-10 (-4%)	-1 (-1%)
	timesfm	+8 (+6%)	+3 (+2%)	+7 (+4%)	+2 (+2%)	+4 (+4%)	+5 (+4%)	+11 (+70%)	+4 (+24%)
	full	subset	full	subset	full	subset	full	subset	

Слика 4.3: Утицај дубине структурне хијерархије (Пуна наспрам Редуковане) на деградацију базних прогноза.

–36% до –60%). Овде је важно разумети саму механику алгорита: MinT користи независно генерисане кварталне прогнозе како би кориговао месечне. Код лоших модела са високим нивоом шума, ове независне кварталне прогнозе су често релативно стабилније од месечних. Када алгоритам дистрибуира ту кварталну корекцију назад на месечни ниво, он ефективно врши пост-хок регуларизацију и смањује укупну варијансу грешке. Код детерминистичких метода (*OLS*) ова дистрибуција је равномерна, док емпиријска *WLS_ Var* метода ово ради интелигентно, тј. асиметрично коригује само оне месеце за које је модел историјски имао високу несигурност. Управо зато *WLS_ Var* доноси и највеће побољшање за лоше моделе.

С друге стране, најбољи предиктивни модели (DeerAR, N-HITS, TimesFM) доживљавају деградацију (повећање WMAPE за +10% до +20%) након темпоралног усклађивања. Ови модели већ генеришу општре и прецизне локалне сигнале на месечном нивоу. Када алгоритам покуша да их усклади са њиховим кварталним прогнозама, он њихов перфектан локални сигнал вештачки дистрибуира и „размазује” унутар квартала. Коначни закључак је да ефикасност СТ усклађивања директно зависи од количине шума у базним прогнозама: оно успешно регуларизује лоше калибрисане моделе, али истовремено доноси деградацију алгоритмима чији је базни сигнал већ оптималан. Стога се хијерархијско усклађивање у врхунским предиктивним системима не сме нужно посматрати као алат за смањење локалне грешке, већ примарно као административни механизам који обезбеђује пословну кохерентност целог система (која је неопходна за корпоративно извештавање и планирање буџета), при чему та кохерентност долази по цену благог пада прецизности на најнижем нивоу.

4.3 Валидација и нарушавање хијерархијске кохерентности

Као што је теоријски дефинисано у Глави 2, основни циљ хијерархијског усклађивања је постизање агрегационе кохерентности система (збир прогноза деце мора бити једнак прогнози родитеља). Интерна евалуација на тест скупу потврдила је да неограничено усклађивање, као и усклађивање уз формална QR ограничења, остварују савршену структурну и темпоралну кохерентност (100% успешних провера над свим чворовима).

Међутим, примена хеуристичког клипинга подразумева нелинеарну трансформацију која неминовно нарушава ову математичку структуру. Како би се квантификовала цена овог инжењерског компромиса, спроведена је анализа. За сваки родитељски чвор упоређена је његова усклађена-па-одсечена вредност са збиром усклађених-па-одсечених вредности његових потомака са базног нивоа.

Табела 4.2: Просечно процентуално нарушавање кохерентности услед хеуристичког клипинга, приказано по нивоима агрегације.

Ниво	Утицај (бр. чворова)	Нарушавање кохерентности (%)
<i>Total</i>	66.7%	6.92%
<i>CBF</i>	47.6%	6.80%
<i>Location</i>	48.6%	6.55%
<i>PH1</i>	36.1%	6.04%
<i>Customer</i>	38.1%	5.81%
<i>PH2</i>	27.3%	5.11%
<i>PH3</i>	23.7%	4.82%
Агрегатно	-	6.00%

Кључни налази ове анализе, сумирани у Табели 4.2, указују на следеће:

- **Укупно нарушавање система:** Агрегатна процентуална грешка кохерентности на нивоу целог система износи **6.00%**. Ово значи да се, у просеку, извештаји на вишим агрегационим нивоима разликују за 6% од физичког збира базних резервних делова услед одсецања негативних прогноза.
- **Дистрибуција по нивоима:** Губитак кохерентности је израженији на највишим нивоима агрегације (укупни *Total* ниво 6.92%, *CBF* категорије 6.80%). Спуштањем кроз производну хијерархију ка грануларнијим нивоима, ово одступање природно опада (*PH3* ниво бележи одступање од 4.82%). Овај феномен је логичан, јер виши нивои сабирају већи број базних серија, чиме се кумулативни ефекат одсечених нула додатно појачава.

Поред агрегационих нивоа, ниво нарушавања кохерентности представља директну последицу интеракције између квалитета базног модела и коришћене матрице усклађивања. Ова динамика приказана је у Табели 4.3.

Табела 4.3: Процентуално нарушавање кохерентности услед хеуристичког клипинга, приказано по базним моделима и примењеним методама усклађивања.

Модел	OLS	WLS_Struct	MinT_Shrink	WLS_Var
<i>DeepAR</i>	15.24	1.11	0.05	0.001
<i>N-HITS</i>	17.72	2.07	0.28	0.01
<i>TimesFM</i>	7.78	0.74	0.06	0.004
<i>Chronos</i>	6.04	0.57	0.03	0.003
<i>Holt-Winters</i>	9.15	2.53	0.67	0.48
<i>Prophet</i>	8.23	1.29	0.48	0.29
<i>ARIMA</i>	12.73	2.13	15.71	0.50
<i>Random Forest</i>	12.58	2.53	48.32	0.06
<i>Random Forest (Dir.)</i>	16.59	2.52	0.11	0.04
<i>LightGBM</i>	13.37	2.19	81.91	0.16
<i>LightGBM (Dir.)</i>	13.91	1.77	54.38	0.26

- **Детерминистички приступ (OLS):** Ова метода је изразито нестабилна на свим моделима. Она слепо дистрибуира корекције и генерише масивне негативне вредности чијим се одсецањем кохерентност трајно нарушава (конзистентно између 6% и 17%).
- **Структурно скалирање (WLS_Struct):** Ова метода представља стабилну средину. Коришћењем саме хијерархијске структуре за апроксимацију несигурности, она значајно ублажава екстреме у односу на *OLS*. Без обзира на квалитет базног модела, задржава губитак кохерентности у уским и пословно прихватљивим границама (између 0.5% и 2.5%).
- **Емпиријски приступи (WLS_Var и MinT_Shrink):** *WLS_Var* метода доказује своју супериорност јер интелигентно скалира корекције према стварној варијанси серија, чиме се потреба за клипингом и губитак кохерентности своде на ниво статистичке грешке (често испод 0.01%). Са друге стране, *MinT_Shrink* метода показује екстремну осетљивост на аутлајере: код квалитетних модела не квари збирове, али у комбинацији са изразито пристрасним *LightGBM*-ом доводи до потпуног распада агрегационе структуре (преко 80% грешке).

4.4 Дискусија добијених резултата

Свеобухватна евалуација на подацима из домена резервних делова преиспитује традиционалне претпоставке о хијерархијском усклађивању. Експеримент недвосмислено показује да усклађивање није универзално решење за побољшање предиктивне тачности. На високо интермитентним подацима, агрегација доноси значајан ниво шума. Уколико се тај шум слепо дистрибуира назад на базни ниво (као код *OLS* методе), долази до катастрофалне деградације локалних сигнала. Када систем користи врхунске алгоритме дубоког учења или фундаменталне моделе, њихове базне прогнозе су већ толико добро калибрисане да им линеарно мешање са вишим нивоима готово уопште не помаже, већ их благо „разводњава”.

Значајан аспект дискусије односи се на утицај дубине, односно дизајна саме структурне хијерархије, на квалитет усклађених прогноза. Поређење пуне и редуковане хијерархије недвосмислено показује да комплекснија структура, са већим бројем међунивоа (агрегационих погледа), уноси додатни шум у систем. Сваки нови ниво уводи додатна ограничења која базне серије морају да задовоље, што алгоритам приморава на непотребну адаптацију локалних сигнала како би се поклопили са удаљеним збировима. Смањењем броја агрегационих погледа (редукована хијерархија), ефективно се смањује број степени слободе у пројекционој матрици, чиме се значајно ублажава деградација базних прогноза. Ово потврђује да дизајн хијерархије не сме бити вођен искључиво организационим корпоративним шемама, већ се мора пажљиво балансирати како алгебарска ограничења не би преоптеретила предиктивни систем.

Ефекат темпоралног усклађивања (СТ) захтева посебно опрезну интерпретацију. Уместо простог математичког усредњавања, СТ алгоритам користи независно генерисане агрегиране (кварталне) прогнозе како би кориговао базне (месечне) сигнале. Детаљна анализа открива да овај процес суштински функционише као механизам пост-хок регуларизације. Дистрибуцијом кварталних вредности наниже, алгоритам ефективно ублажава екстремне локалне осцилације и масивну пристрасност лоших модела, чиме им стварно и значајно смањује укупну грешку. Међутим, инхерентна цена ове регуларизације је вештачко „размазивање” већ прецизних локалних сигнала код висококвалитетних модела. Због тога, закључак да СТ усклађивање побољшава систем

у просеку заправо представља последицу екстремних поправки најлошијих модела. У реалности, напредним алгоритмима ова врста темпоралне интервенције не доноси предиктивни бенефит, већ доводи до благог пада њихове иницијалне прецизности.

Коначно, анализа доменских ограничења потврђује да је у индустријској пракси инжењерски компромис често супериорнији од строге математике. Иако формално квадратно програмирање (QP) гарантује кохерентност без одсецања, његова рачунарска нестабилност чини га неупотребљивим за системе са 20.000 серија. Хеуристички клипинг на нулу успешно решава овај проблем уз занемарљиву цену: упарен са интелигентном *WLS_Var* методом, он нарушава математичку кохерентност система за мање од 0.5%, што је у пословном извештавању углавном потпуно прихватљива маргина грешке.

4.5 Идентификација најбољих пракси за дати проблем

На основу синтезе резултата, дефинисане су конкретне инжењерске препоруке за пројектовање предиктивних система у описаном домену:

1. **Избор алгоритама:** Приоритет треба дати вероватносним (*DeepAR*) или фундационим моделима (*Chronos*, *TimesFM*) посебно ако нам је потребно да брзо дођемо до иницијалних резултата. Класична стабла одлучивања (*LightGBM*, *Random Forest*) не треба користити на скупу са великим уделом интермитентних података без претходне промене функције циља и инжењеринга карактеристика.
2. **Стратегија примене усклађивања (CSM или СТ):** Одлука о димензији усклађивања мора бити директно вођена пословним приоритетима:
 - Уколико је **максимална тачност на базном нивоу** апсолутни приоритет (нпр. за аутоматизовано наручивање делова), а користе се квалитетни модели, хијерархијско усклађивање треба **потпуно избегавати**.
 - Уколико су **кохерентни извештаји** неопходни за менаџмент, применити структурно усклађивање (CSM), али искључиво кроз ***WLS_Var***

методу, и уз пажљив избор хијерархија, како би се сачувао интегритет добрих базних модела.

- Темпорално усклађивање (СТ) треба стратешки користити искључиво као механизам пост-хок регуларизације у системима где се нужно користе лошији, нестабилни модели са високом варијансом. За добре моделе, СТ не доноси побољшања.

3. **Третман негативних прогноза:** Уместо нумерички нестабилних QR решавача, препоручује се неограничено усклађивање праћено хеуристичким одсецањем на нулу (Clipping). Упарен са WLS_Var методом, овај приступ нуди максималну стабилност уз занемарљив губитак кохерентности.
4. **Дизајн хијерархије:** Комплексност агрегације треба свести на апсолутни минимум. Увођење непотребних међунивоа у структурну хијерархију повећава број степени слободе и доводи до прекомерних, штетних корекција базних серија.

Глава 5

Закључак

5.1 Синтеза кључних налаза истраживања

У овом мастер раду спроведена је свеобухватна анализа утицаја хијерархијског усклађивања на прецизност предвиђања временских серија, мотивисана индустријским проблемом предвиђања потражње резервних делова. Специфичност овог домена огледа се у високој димензионалности, сложеној структури агрегације и изразитој интермитентности података.

Најзначајнији допринос овог рада лежи у побијању претпоставке да хијерархијско усклађивање аутоматски побољшава локалну прецизност модела. Резултати недвосмислено доказују да врхунски алгоритми, посебно фундаментални модели (*Chronos*, *TimesFM*) и пробабилистичке неуронске мреже (*DeepAR*), екстрахују максимум релевантних информација директно из сирових података. Накнадно линеарно мешање таквих добро калибрисаних локалних сигнала са независним агрегираним нивоима кроз MinT алгоритме не доноси предиктивни бенефит, већ често уноси шум. За високо прецизне моделе, хијерархијско усклађивање се стога мора посматрати превасходно као неопходан административни механизам за корпоративно извештавање, а не као алатка за минимизацију локалне грешке.

Значајан налаз ове студије је и директан утицај самог дизајна хијерархије на резултате усклађивања. Доказано је да комплекснија структура са већим бројем агрегационих погледа уноси додатни шум у систем. Редукована хијерархија (са мањим бројем нивоа) показала се као супериорна, јер смањење броја степени слободе у матрици сабирања ефективно ограничава нежељену прекомпензацију базних серија.

Поред тога, рад се дотакао и решавања конфликта између строге математичке кохерентности и пословних ограничења (ненегативности). Показали смо да је у високодимензионалним системима замена нестабилне формалне оптимизације (QP) рачунарски јефтиним хеуристикама (одсецање на нулу) апсолутно неопходна за физичку употребљивост прогноза. Упарен са методама које поштују историјску варијансу (попут *WLS_Var*), овај инжењерски компромис чува агрегациони интегритет система уз занемарљив губитак математичке кохерентности.

5.2 Ограничења спроведене студије

Као и свако истраживање, и ово има своја ограничења која треба узети у обзир приликом интерпретације резултата.

Прво ограничење односи се на рачунарске и математичке ресурсе при раду са високодимензионалним системима. Због екстремне меморијске захтевности, није било могуће извршити експлицитну алокацију масивне матрице за истовремено (заједничко) структурно и темпорално усклађивање над 20.000 серија. Такође, због природе података где је број серија знатно већи од броја доступних временских корака ($N > T$), математички је немогуће инвертовати пуну емпиријску коваријансну матрицу. Због тога није било могуће тестирати класични MinT алгоритам (енгл. *MinT Sample*).

Друго ограничење везано је за моделе класичног машинског учења (*LightGBM*, *Random Forest*). Ови алгоритми су намерно тренирани искључиво са историјским (енгл. *lags*) и календарским карактеристикама, уз стандардну MSE функцију циља. Разлог за овако скроман избор улазних података било је фер поређење са униваријантним статистичким и фундаменталним моделима, којима је доступна искључиво историја циљне променљиве. Иако је тиме спречено да се моделима заснованим на стаблима даје предност кроз екстерне информације, то уједно значи да приказане перформансе ових алгоритама у раду не представљају њихов теоријски максимум.

Коначно, важно је нагласити да су сви закључци изведени на специфичном скупу података из домена потражње резервних делова, који одликује екстремна интермитентност и велики број нултих вредности. Ови резултати се не могу аутоматски генерализовати; постоји велика вероватноћа да би на „глатким” временским серијама са стабилним и великим волуменом продаје

(нпр. у класичној малопродаји робе широке потрошње) линеарно мешање кроз MinT алгоритме дало значајно другачије, вероватно повољније резултате.

5.3 Препоруке за будућа истраживања и практичну примену

Претходно наведена ограничења директно инспиришу и дефинишу правце за будућа истраживања. Када је реч о предиктивном моделирању, логичан наредни корак био би развој модела заснованих на стаблима кроз имплементацију прилагођених функција губитка и увођење богатијег скупа екстерних карактеристика. Ово би омогућило да се испита да ли ти алгоритми могу да парирају фундаменталним моделима када нису ограничени. Такође, репликација ове експерименталне поставке на скуповима „глатких” временских серија високог волумена омогућила би компаративну анализу понашања MinT алгоритама у суштински различитим тржишним условима.

У домену алгоритмике усклађивања, будућа истраживања би се могла фокусирати на технике смањења димензионалности које би омогућиле апроксимацију класичног MinT приступа чак и када је $N > T$, као и на алгоритамску оптимизацију меморијских захтева за заједничко структурно-временско усклађивање. Код пробабилистичких модела фокус би се могао померити на пробабилистичко усклађивање, где би се кроз хијерархију уместо тачкастих прогноза пројектовале целе вероватносне расподеле. Такође, постоји огроман потенцијал у интеграцији најновијих парадигми неуронског усклађивања (енгл. *Neural Reconciliation*) [15]. Уместо ослањања на фиксне линеарне пројекције (попут MinT матрица), ови савремени приступи користе архитектуре попут аутоенкодера или вишеслојних перцептрона (MLP) како би директно из података научили оптималне, нелинеарне мапирајуће функције. Имплементација оваквих нелинеарних алгоритама представља један од најобећавајућих праваца тренутно.

У практичном смислу, овај рад демистификује компромисе између статистичке тачности, алгебарске кохерентности и рачунарске стабилности, нудећи директне смернице за пројектовање робусних предиктивних система у савременим ланцима снабдевања.

Библиографија

- [1] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, et al. Chronos: Learning the language of time series. *arXiv preprint arXiv:2403.07815*, 2024.
- [2] George Athanasopoulos, Roman A Ahmed, and Rob J Hyndman. Hierarchical forecasts for australian domestic tourism. *International Journal of Forecasting*, 25(1):146–166, 2009.
- [3] George Athanasopoulos, Rob J Hyndman, Nikolaos Kourentzes, and Fotios Petropoulos. Forecasting with temporal hierarchies. *European Journal of Operational Research*, 262(1):60–74, 2017.
- [4] Leo Breiman. Random forests. *Machine learning*, 45(1):5–32, 2001.
- [5] Cristian Challu, Kin G Olivares, Boris N Oreshkin, Federico Garza Ramirez, Max Mergenthaler Canseco, and Artur Dubrawski. N-hits: Neural hierarchical interpolation for time series forecasting. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 37, pages 6989–6997, 2023.
- [6] Byron J Dangerfield and John S Morris. Bottom-up or top-down: Summary versus item forecasting. *International Journal of Forecasting*, 8(2):233–241, 1992.
- [7] Abhimanyu Das, Weihao Kong, Rajat Sen, and Yichen Zhou. A decoder-only foundation model for time-series forecasting. *arXiv preprint arXiv:2310.10688*, 2023.
- [8] Charles W Gross and Jeffrey E Sohl. Disaggregation methods to expedite product line forecasting. *Journal of Forecasting*, 6(4):233–254, 1990.

- [9] Rob J Hyndman, Roman A Ahmed, George Athanasopoulos, and Han Lin Shang. Optimal combination forecasts for hierarchical time series. *Computational Statistics & Data Analysis*, 55(9):2579–2589, 2011.
- [10] Rob J Hyndman and George Athanasopoulos. *Forecasting: principles and practice*. OTexts, 3rd edition, 2021.
- [11] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Liu Tie-Yan. Lightgbm: A highly efficient gradient boosting decision tree. In *Advances in neural information processing systems*, volume 30, 2017.
- [12] Nikolaos Kourentzes and George Athanasopoulos. Cross-temporal coherent forecasts for australian tourism. *Annals of Tourism Research*, 75:393–409, 2019.
- [13] Bryan Lim, Sercan Ö Arık, Nicolas Loeff, and Tomas Pfister. Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*, 37(4):1748–1764, 2021.
- [14] Spyros Makridakis, Evangelos Spiliotis, and Vassilios Assimakopoulos. The m4 competition: 100,000 time series and 61 forecasting methods. *International Journal of Forecasting*, 36(1):54–74, 2020.
- [15] Paul Mancuso, Vincenzo Picillo, and Michele Rubattu. Machine learning for hierarchical forecasting. *International Journal of Forecasting*, 37(4):1670–1686, 2021.
- [16] Kin G Olivares, Cristian Challu, Federico Garza, Max Mergenthaler Canseco, and Artur Dubrawski. Hierarchicalforecast: A reference framework for hierarchical forecasting in python. *arXiv preprint arXiv:2207.03517*, 2022.
- [17] Boris N Oreshkin, Dmitri Carpov, Nicolas Chapados, and Yoshua Bengio. N-beats: Neural basis expansion analysis for interpretable time series forecasting. In *International Conference on Learning Representations (ICLR)*, 2020.
- [18] David Salinas, Valentin Flunkert, Jan Gasthaus, and Tim Januschowski. Deepar: Probabilistic forecasting with autoregressive recurrent networks. *International Journal of Forecasting*, 36(3):1181–1191, 2020.

- [19] Juliane Schäfer and Korbinian Strimmer. A shrinkage approach to large-scale covariance matrix estimation and implications for functional genomics. *Statistical Applications in Genetics and Molecular Biology*, 4(1), 2005.
- [20] Sean J Taylor and Benjamin Letham. Forecasting at scale. *The American Statistician*, 72(1):37–45, 2018.
- [21] Shanika L Wickramasuriya, George Athanasopoulos, and Rob J Hyndman. Optimal forecast reconciliation for hierarchical and grouped time series through trace minimization. *Journal of the American Statistical Association*, 114(526):804–819, 2019.

Биографија аутора